

**HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG**



**Cao Việt Anh**

**NGHIÊN CỨU ỨNG DỤNG HỌC MÁY ĐỂ PHÁT HIỆN VẬN  
ĐỘNG BẤT THƯỜNG**

**ĐỀ ÁN TỐT NGHIỆP THẠC SĨ KỸ THUẬT**  
*(Theo định hướng ứng dụng)*

HÀ NỘI- NĂM 2024

**HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG**

---



**Cao Việt Anh**

**NGHIÊN CỨU ỨNG DỤNG HỌC MÁY ĐỂ PHÁT HIỆN VẬN  
ĐỘNG BẤT THƯỜNG**

**Chuyên ngành : Khoa học máy tính**

**Mã số: 8.48.01.01**

**ĐỀ ÁN TỐT NGHIỆP THẠC SĨ KỸ THUẬT**  
*(Theo định hướng ứng dụng)*

**NGƯỜI HƯỚNG DẪN KHOA HỌC**  
**TS. NGUYỄN TẮT THẮNG**

**HÀ NỘI- NĂM 2024**

## LỜI CAM ĐOAN

Tôi cam đoan tất cả nội dung trong đề án “*Nghiên cứu ứng dụng học máy để phát hiện vận động bất thường*” là công trình nghiên cứu của riêng tôi dưới sự hướng dẫn, chỉ bảo, góp ý của TS. Nguyễn Tất Thắng, giảng viên Khoa Công nghệ thông tin 1, Học viện Công nghệ Bưu chính Viễn thông. Các số liệu, kết quả nêu trong đề án tốt nghiệp là trung thực và chưa từng được ai công bố trong bất kỳ công trình nào khác và không sao chép dưới mọi hình thức. Các tài liệu tham khảo trong đề án được trích dẫn đầy đủ, rõ ràng.

Tôi xin chịu mọi trách nhiệm về công trình nghiên cứu của riêng mình !

**Tác giả đề án**

**Cao Việt Anh**

## LỜI CẢM ƠN

Lời đầu tiên và trên hết, em xin bày tỏ lời cảm ơn sâu sắc đến người hướng dẫn khoa học TS. Nguyễn Tất Thắng – Giảng viên khoa Công nghệ thông tin 1, Học viện công nghệ bưu chính viễn thông, người hướng dẫn trực tiếp về mặt khoa học một cách tận tình. Chính những kiến thức, sự chỉ bảo tận tâm, sự động viên cổ vũ của thầy đã giúp em có động lực hơn trong quá trình hoàn thành đề án.

Em cũng xin chân thành cảm ơn toàn thể giảng viên của học viện nói chung và khoa Đào tạo Sau Đại học nói riêng đã luôn giúp đỡ, luôn nhiệt tâm giảng dạy, hướng dẫn và chia sẻ những kiến thức và kinh nghiệm quý báu cho em trong suốt những năm học vừa qua về lĩnh vực ICT nói chung và lĩnh vực Viễn thông nói riêng. Đối với em, đây là một hành trình tương đối khó khăn và đầy thử thách, cả trong thời gian học tập cũng như nghiên cứu. Nhưng nhờ sự giúp đỡ và tận tình chỉ dạy của các thầy cô trong quá trình học Thạc sĩ tại trường, em đã có thêm những kiến thức, được tạo nền tảng, dạy cách tư duy, định hướng để em có thể hoàn thành quá trình học tập và thực hiện đề án này và giúp em có thể tự tin hơn trong những hành trang phía trước của mình.

Cuối cùng, em dành những lời yêu thương nhất đến gia đình em. Sự động viên, giúp đỡ và sự hi sinh, nhẫn nại của họ là động lực mạnh mẽ giúp tôi vượt qua mọi khó khăn để hoàn thành đề án này.

Xin chân thành cảm ơn!

## MỤC LỤC

LỜI CAM ĐOAN .....	i
LỜI CẢM ƠN .....	ii
MỤC LỤC .....	iii
DANH MỤC CHỮ VIẾT TẮT .....	v
DANH MỤC BẢNG .....	vi
DANH MỤC HÌNH ẢNH.....	vii
MỞ ĐẦU .....	1
CHƯƠNG 1 -TỔNG QUAN VỀ BÀI TOÁN PHÁT HIỆN VẬN ĐỘNG BẤT THƯỜNG .....	3
1.1 Giới thiệu chung về phát hiện bất thường .....	3
1.2 Tổng quan về phát hiện vận động bất thường.....	5
1.2.1 Định nghĩa .....	5
1.2.2 Thách thức trong bài toán phát hiện bất thường.....	8
1.3 Một số hệ thống phát hiện vận động bất thường .....	9
1.3.1 Hệ thống phát hiện vận động bất thường trên thế giới .....	9
1.3.2 Hệ thống phát hiện vận động bất thường ở Việt Nam .....	13
1.4 Dữ liệu cảm biến cho nhận dạng hoạt động ở người .....	14
1.5 Kết luận chương 1 .....	17
CHƯƠNG 2 – NGHIÊN CỨU THUẬT TOÁN VÀ CẢM BIẾN PHÁT HIỆN VẬN ĐỘNG BẤT THƯỜNG ỨNG DỤNG MÔ HÌNH HỌC MÁY.....	18
2.1 Giới thiệu chung .....	18
2.2 Sơ đồ tổng quát hệ thống phát hiện vận động bất thường.....	19
2.3 Thuật toán phát hiện vận động bất thường truyền thống.....	20
2.3.1 Phương pháp thống kê .....	20
2.3.1 Phương pháp dựa trên khoảng cách .....	22
2.4 Thuật toán phát hiện vận động bất thường thông minh sử dụng mô hình học máy.....	25
2.4.1 Một số mô hình mạng nơ-ron.....	28
2.4.2 Mô hình CNN.....	28
2.5 Cảm biến và tập dữ liệu sử dụng trong mô hình vận động bất thường.....	30

2.6	Kết luận chương 2 .....	31
<b>CHƯƠNG 3 - ÁP DỤNG HỌC MÁY VÀO PHÁT HIỆN VẬN ĐỘNG BẤT THƯỜNG</b> .....		
3.1	Mô hình đề xuất.....	34
3.1.1	Dữ liệu thu thập .....	35
3.1.2	Tiền xử lý dữ liệu .....	37
3.1.3	Trích chọn đặc trưng.....	39
3.1.4	Mô hình học sâu.....	40
3.2	Thực hiện mô hình.....	42
3.3	Kiểm thử và đánh giá .....	44
3.3.1	Các tham số đánh giá .....	44
3.3.2	Đánh giá hiệu năng mô hình .....	46
3.4	Kết luận chương 3 .....	50
<b>KẾT LUẬN VÀ KIẾN NGHỊ</b> .....		51
<b>DANH MỤC TÀI LIỆU THAM KHẢO</b> .....		52
<b>BẢN CAM ĐOAN</b> .....		53

## DANH MỤC CHỮ VIẾT TẮT

Từ viết tắt	Nghĩa Tiếng Anh	Nghĩa Tiếng Việt
ADC	Analogue to Digital Converter	Bộ chuyển đổi tín hiệu tương tự sang số
AI	Artificial Intelligence	Trí tuệ nhân tạo
ANN	Artificial Neural Network	Mạng nơ-ron nhân tạo
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
DNN	Deep Neural Network	Mạng nơ-ron sâu
DL	Deep Learning	Học sâu
CSV	Character Separated Values	Giá trị ngăn cách bằng ký tự
FFT	Fast Fourier Transform	Biến đổi Fourier nhanh
GPS	Global Positioning System	Hệ thống định vị toàn cầu
IoT	Internet of Things	Internet vạn vật
MCU	Microcontroller Unit	Vi điều khiển
ML	Machine Learning	Học máy
MQTT	Message Queuing Telemetry Transport	Giao thức chuyển hàng đợi tin nhắn từ xa
PDF	Probability Density Function	Hàm mật độ xác suất
PSD	Power Spectral Density	Mật độ phổ công suất
SOS	Universal distress signal	Tín hiệu cầu cứu
Tiny ML	Tiny Machine Learning	Mô hình học máy nhỏ
RL	Reinforcement Learning	Học tăng cường
RNN	Recurrent Neural Network	Mạng nơ-ron tái tạo
RMS	Root Mean Square	Hàm trung bình bình phương

## DANH MỤC BẢNG

Bảng 1.1. So sánh các thiết bị phát hiện vận động bất thường đã được thương mại hóa .....	13
Bảng 2.1. Một số giá trị xác suất của phân bố Gauss theo giá trị $c$ .....	21
Bảng 3.1. Mô tả chi tiết phần cứng sử dụng .....	34
Bảng 3.2. Chi tiết tập dữ liệu thu thập .....	36
Bảng 3.3. Chi tiết mô hình học sâu phát hiện vận động bất thường .....	41
Bảng 3.4. Ma trận nhầm lẫn (confusion matrix).....	44
Bảng 3.5. Tham số đánh giá cho từng loại dữ liệu.....	49



## DANH MỤC HÌNH ẢNH

Hình 1.1. Mô tả phát hiện bất thường.....	3
Hình 1.2. Ứng dụng của phát hiện bất thường trong nhiều lĩnh vực.....	7
Hình 1.3. Thiết bị đồng hồ và dây đeo SureSafeGo.....	10
Hình 1.4. Thiết bị cảnh báo y tế Sentry.....	11
Hình 1.5. Thiết bị đeo phát hiện ngã GreatCall Lively.....	11
Hình 1.6. Thiết bị phát hiện ngã Buddi.....	12
Hình 1.7. Các loại dữ liệu cảm biến từ những bộ phận cơ thể người khác nhau.....	15
Hình 2.1. Mô hình hệ thống phát hiện bất thường .....	20
Hình 2.2. Hàm mật độ xác suất (PDF) trong phân bố Gauss.....	21
Hình 2.3. Linh kiện sử dụng thu thập dữ liệu (a) cảm biến MPU6050 (b) vi điều khiển ESP32-S3 .....	31
Hình 3.1. Mô hình hệ thống đề xuất phát hiện vận động bất thường.....	35
Hình 3.2. Phần cứng thiết bị phát hiện vận động bất thường.....	36
Hình 3.3. Tiền xử lý dữ liệu thu thập.....	38
Hình 3.4. Quá trình tiền xử lý dữ liệu sử dụng FFT kết hợp của sổ trượt.....	39
Hình 3.5. Trực quan hóa mô hình học sâu phát hiện vận động bất thường .....	40
Hình 3.6. Hình ảnh triển khai thiết bị vận động bất thường trên thực tế.....	44
Hình 3.7. Độ chính xác theo giá trị Epoch trong quá trình huấn luyện và xác thực	47
Hình 3.8. Giá trị mất mát theo giá trị Epoch trong quá trình huấn luyện và xác thực .....	47
Hình 3.9. Ma trận nhầm lẫn của mô hình trong quá trình kiểm thử.....	48
Hình 3.10. Các tham số đánh giá cho từng trạng thái hoạt động.....	49
Hình 3.11. Tình huống người ngã và còi cảnh báo sẽ kêu.....	50

## MỞ ĐẦU

Các vận động bất thường, đặc biệt là ngã, gây nguy hiểm và ảnh hưởng tiêu cực đến sức khỏe, đặc biệt ở người cao tuổi. Việc tự động phát hiện các vận động này để cảnh báo và hỗ trợ kịp thời đã thu hút sự quan tâm của nhiều nhà nghiên cứu [1]. Sự phát triển của công nghệ tính toán di động và cảm biến thông minh tích hợp trong các thiết bị như điện thoại, đồng hồ thông minh, và kính đã mở ra cơ hội phân tích tín hiệu vận động hàng ngày để cung cấp thông tin về sức khỏe. Hệ thống phát hiện ngã là một công cụ hỗ trợ với mục đích chính là tạo ra cảnh báo nếu xảy ra ngã. Những hệ thống này cho thấy hứa hẹn lớn trong việc giảm bớt một số tác động tiêu cực của ngã. Các thiết bị phát hiện ngã có ảnh hưởng đáng kể đến việc cung cấp sự trợ giúp ngay lập tức sau khi xảy ra ngã cũng như giảm nỗi sợ hãi khi ngã. Ngã và sự sợ hãi về việc ngã có mối liên hệ: sự sợ hãi khi bị ngã có thể làm tăng khả năng một người sẽ bị ngã [2].

Nhiều nghiên cứu đã được thực hiện để tạo ra các chiến lược và phương pháp nhằm cải thiện khả năng chức năng của người cao tuổi và người ốm. Một số hệ thống sử dụng camera, cảm biến và công nghệ máy tính [3]. Những hệ thống như vậy cho người cao tuổi có thể vừa cải thiện khả năng sống độc lập bằng cách nâng cao cảm giác an toàn trong môi trường hỗ trợ, vừa giảm bớt khối lượng công việc chăm sóc bằng cách giảm nhu cầu sử dụng y tá hoặc nhân viên hỗ trợ khác [4-6]. Tuy nhiên, nhiều hệ thống phát hiện vận động bất thường hiện có chi phí cao và chưa phù hợp với điều kiện tại Việt Nam. Do đó, đề án này tập trung nghiên cứu các phương pháp học máy để phát hiện vận động bất thường, đặc biệt là ngã, sử dụng cảm biến đeo, thực hiện theo thời gian thực nhằm đáp ứng nhu cầu trong nước.

Với lý do trên, học viên đã quyết định lựa chọn đề tài ***“Nghiên cứu ứng dụng học máy để phát hiện vận động bất thường”*** để thực hiện đề án tốt nghiệp thạc sĩ. Nội dung đề án tốt nghiệp được trình bày theo 3 chương như sau:

✓ **Chương 1: Tổng quan về bài toán phát hiện vận động bất thường;**

- ✓ **Chương 2: Nghiên cứu thuật toán và cảm biến phát hiện vận động bất thường ứng dụng mô hình học máy;**
- ✓ **Chương 3: Áp dụng học máy vào phát hiện vận động bất thường.**

# CHƯƠNG 1 - TỔNG QUAN VỀ BÀI TOÁN PHÁT HIỆN VẬN ĐỘNG BẤT THƯỜNG

## 1.1 Giới thiệu chung về phát hiện bất thường

Phát hiện bất thường là một lĩnh vực nghiên cứu quan trọng trong khoa học dữ liệu tập trung vào việc nhận diện các mẫu dữ liệu hoặc hành vi không tuân theo các quy luật thông thường qua các phương pháp thống kê truyền thống hay phương pháp sử dụng trí tuệ nhân tạo (AI) và học máy (ML). Những bất thường này có thể biểu thị các tình huống bất thường, các nguy cơ tiềm ẩn hoặc các sự kiện quan trọng cần chú ý. Tuy nhiên, phát hiện bất thường không chỉ đơn thuần là việc tìm kiếm những giá trị nằm ngoài các ngưỡng quy định. Đây là một bài toán phức tạp bởi khái niệm “bất thường” thường phụ thuộc vào ngữ cảnh cụ thể. Một hành vi có thể được coi là bình thường trong ngữ cảnh này nhưng lại bất thường trong ngữ cảnh khác. Ngoài ra, dữ liệu bất thường thường rất hiếm và có tính không đồng nhất, gây khó khăn trong việc phát triển các mô hình phát hiện hiệu quả.



**Hình 1.1. Mô tả phát hiện bất thường**

Phát hiện bất thường có rất nhiều ứng dụng thực tiễn, đóng vai trò quan trọng trong việc cải thiện hiệu suất hệ thống, đảm bảo an toàn và giảm thiểu rủi ro trong nhiều lĩnh vực. Một số ứng dụng tiêu biểu:

- Y tế và chăm sóc sức khỏe

- An ninh và giám sát
- Công nghiệp và sản xuất
- Giao thông và vận tải
- IoT và nhà thông minh
- Tài chính và ngân hàng

Trong số đó, lĩnh vực y tế và chăm sóc sức khỏe đóng vai trò nổi bật vì liên quan trực tiếp đến sức khỏe và tính mạng con người. Trong y tế, phát hiện bất thường được sử dụng để theo dõi các chỉ số sinh học và hành vi của bệnh nhân nhằm kịp thời phát hiện các tình huống khẩn cấp hoặc dấu hiệu bệnh lý. Một trong những ứng dụng điển hình là giám sát bệnh nhân trong thời gian thực. Hệ thống cảm biến và camera thông minh có thể phát hiện các tình huống nguy hiểm như té ngã, co giật, hoặc các thay đổi bất thường trong hành vi của bệnh nhân, đặc biệt hữu ích trong viện dưỡng lão, bệnh viện hoặc khi chăm sóc bệnh nhân tại nhà. Bên cạnh đó, các thiết bị đeo thông minh như đồng hồ thông minh hoặc vòng tay sức khỏe cũng sử dụng AI để phân tích các chỉ số như nhịp tim, nhiệt độ cơ thể, và nhịp thở. Khi phát hiện bất thường, hệ thống sẽ gửi cảnh báo đến nhân viên y tế hoặc người thân của bệnh nhân. Điều này đặc biệt quan trọng trong việc hỗ trợ người cao tuổi hoặc người khuyết tật, giúp họ sống độc lập nhưng vẫn đảm bảo an toàn. Một ứng dụng khác là chẩn đoán bệnh tự động dựa trên dữ liệu cảm biến hoặc hình ảnh y tế. Các hệ thống này sử dụng các mô hình học sâu (DL-Deep Learning) để phát hiện các bất thường trong hình ảnh X-quang, MRI hoặc ECG. Ví dụ, hệ thống có thể tự động nhận diện các dấu hiệu bất thường liên quan đến bệnh tim mạch, đột quỵ, hoặc ung thư. Việc này không chỉ giúp giảm tải cho bác sĩ mà còn cải thiện độ chính xác trong chẩn đoán.

Ngoài y tế, phát hiện bất thường cũng được ứng dụng trong nhiều lĩnh vực khác. Trong an ninh và giám sát, các hệ thống phát hiện bất thường được sử dụng để nhận diện hành vi khả nghi hoặc các vật thể lạ trong khu vực giám sát, từ đó ngăn chặn kịp thời các hành vi xâm nhập hoặc gây hại. Tương tự, trong công nghiệp, các hệ thống này giúp theo dõi tình trạng hoạt động của máy móc, phát hiện lỗi hoặc dự đoán hỏng hóc để giảm thiểu thời gian ngừng hoạt động. Trong lĩnh vực giao thông,

các hệ thống giám sát giao thông thông minh sử dụng AI để phát hiện các tai nạn hoặc hành vi lái xe nguy hiểm như vượt đèn đỏ, chuyển làn đột ngột. Điều này không chỉ tăng cường an toàn giao thông mà còn cải thiện hiệu quả vận hành mạng lưới giao thông. Cuối cùng, trong IoT và nhà thông minh, các thiết bị phát hiện bất thường giúp giám sát các thiết bị gia dụng, phát hiện rủi ro như cháy nổ, tiêu thụ năng lượng bất thường, hoặc chuyển động khả nghi trong nhà. Những ứng dụng này mang lại sự tiện lợi và an toàn cao cho người dùng.

## **1.2 Tổng quan về phát hiện vận động bất thường**

### ***1.2.1 Định nghĩa***

Vận động bất thường (VĐBT) là những chuyển động xảy ra không có chủ ý, thường diễn ra trong khoảng thời gian ngắn và để lại những hậu quả không mong muốn như chấn thương hoặc va đập. Một ví dụ điển hình của vận động bất thường là té ngã, sự kiện có thể xảy ra trong khi con người thực hiện các hoạt động thường ngày. Những vận động này không thường xuyên, khó dự đoán trước, và có thể dẫn đến các tình huống nguy hiểm, đặc biệt đối với người cao tuổi hoặc những người cần được chăm sóc đặc biệt.

Bài toán phát hiện vận động bất thường ngày càng thu hút sự quan tâm của các nhà nghiên cứu nhờ tính ứng dụng cao, như hỗ trợ chăm sóc sức khỏe người cao tuổi và cung cấp cảnh báo sớm để giảm thiểu mức độ nghiêm trọng của các sự cố. Tuy nhiên, việc phát triển các hệ thống này đối mặt với nhiều thách thức, đặc biệt là trong giai đoạn huấn luyện mô hình. Một trong những rào cản lớn nhất là sự khan hiếm dữ liệu về hành động và hành vi bất thường, dẫn đến hiệu suất của các hệ thống phát hiện chưa đạt được độ chính xác mong muốn.

Các phương pháp tiếp cận theo cảm biến: Trong lĩnh vực phát hiện vận động bất thường, các nghiên cứu thường sử dụng các phương pháp dựa trên cảm biến, có thể chia thành ba loại chính:

- Thị giác máy (camera): Phân tích hình ảnh hoặc video để nhận diện hành vi bất thường.

- Cảm biến tích hợp môi trường: Thu thập dữ liệu từ các thiết bị cảm biến được cài đặt trong môi trường sống hoặc làm việc.
- Cảm biến đeo (wearable sensors): Gắn trực tiếp trên cơ thể người để theo dõi hành vi liên tục.

So với thị giác máy, các cảm biến đeo mang lại nhiều lợi ích nổi bật, như khả năng theo dõi liên tục trong thời gian dài mà không gây mất quyền riêng tư. Các cảm biến đeo cũng ít bị ảnh hưởng bởi các yếu tố môi trường như ánh sáng hoặc vật cản. Tuy nhiên, chúng đặt ra những thách thức mới, bao gồm việc xử lý dữ liệu không đồng nhất từ nhiều cảm biến, giới hạn về khả năng lưu trữ và xử lý dữ liệu, cũng như yêu cầu về năng lượng để đảm bảo hoạt động lâu dài.

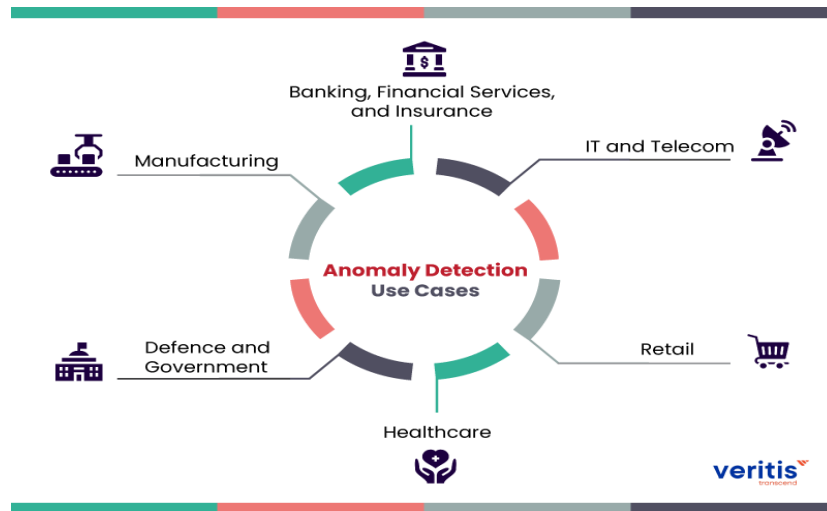
Các phương pháp xử lý dữ liệu sẽ được trình bày chi tiết ở trong chương 2: Các nghiên cứu phát hiện vận động bất thường thường tiếp cận theo hai hướng chính:

- Phương pháp truyền thống: Sử dụng các kỹ thuật như phân tích thống kê hoặc xử lý tín hiệu để phát hiện hành vi bất thường.
- Phương pháp thông minh: Áp dụng trí tuệ nhân tạo (AI) và học máy (ML), cho phép hệ thống tự học từ dữ liệu và cải thiện độ chính xác trong việc nhận diện các mẫu hành vi bất thường.

Việc kết hợp các phương pháp cảm biến và kỹ thuật xử lý thông minh đang mở ra tiềm năng lớn trong việc xây dựng các hệ thống phát hiện vận động bất thường hiệu quả hơn, góp phần nâng cao chất lượng cuộc sống và đảm bảo an toàn cho con người.

Bài toán phát hiện bất thường có nhiều ứng dụng trong các lĩnh vực chăm sóc sức khỏe, an ninh – an toàn và bảo mật. Trong lĩnh vực chăm sóc sức khỏe, vận động bất thường gây ra những hậu quả đáng tiếc cho con người (điển hình là ngã) hay có thể là những biểu hiện ban đầu ở người có bệnh lý về vận động. Do vậy, rất cần có một hệ thống phát hiện vận động bất thường giúp theo dõi, hỗ trợ người bệnh, người cao tuổi, hơn nữa có thể phát hiện và cảnh báo sớm nhằm tối thiểu hóa hậu quả. Đối với lĩnh vực an ninh – an toàn và bảo mật, giả sử cần theo dõi hoạt động của tất cả mọi người trong một khu vực cần bảo vệ đặc biệt, người ta sử dụng các cảm biến (có

thể gắn trên các cá thể định danh). Các cảm biến giúp theo dõi hoạt động, nếu có hành động hoặc hành vi được coi là bất thường, hệ thống sẽ cảnh báo cho bộ phận quản lý về rủi ro an ninh – an toàn.



**Hình 1.2. Ứng dụng của phát hiện bất thường trong nhiều lĩnh vực**

Nhiều nghiên cứu đã đạt được thành công trong việc nhận diện các hoạt động thường ngày của con người như đi bộ, đứng, ngồi, chạy, nhảy, hoặc tập luyện thể thao. Tuy nhiên, vận động bất thường lại mang những đặc điểm đặc thù: chúng xảy ra không thường xuyên, diễn ra trong thời gian ngắn, thiếu tính chủ động và khó mô tả chính xác. Những vận động này thường không lặp lại và có tính chất phức tạp, gây khó khăn trong việc thu thập dữ liệu huấn luyện, từ đó làm giảm hiệu suất của các hệ thống phát hiện khi triển khai thực tế. Đây là một thách thức lớn đối với bài toán nhận diện vận động bất thường.

Cùng với sự tiến bộ của công nghệ, cơ hội cải thiện hiệu quả phát hiện vận động bất thường đã trở nên rõ ràng hơn. Các thiết bị hiện đại có khả năng ghi nhận một lượng lớn dữ liệu chuyển động của con người theo thời gian thực, tạo điều kiện để ứng dụng các phương pháp học máy và trí tuệ nhân tạo trong việc phát hiện tự động những vận động bất thường. Việc áp dụng các công nghệ tự động này không chỉ giúp giảm bớt khối lượng công việc cho nhân viên y tế mà còn nâng cao khả năng chẩn đoán sớm và cải thiện chất lượng điều trị cho bệnh nhân.



Tóm lại, bài toán phát hiện vận động bất thường không chỉ là một thách thức kỹ thuật mà còn có tầm quan trọng to lớn trong việc cải thiện chăm sóc sức khỏe, đặc biệt là đối với nhóm người cao tuổi và những người mắc các bệnh lý về vận động. Sự phát triển của công nghệ và ứng dụng của trí tuệ nhân tạo hứa hẹn mở ra một tương lai sáng sủa, nơi mà việc phát hiện và quản lý các vận động bất thường trở nên hiệu quả và tiết kiệm thời gian hơn bao giờ hết.

### ***1.2.2 Thách thức trong bài toán phát hiện bất thường***

Trong những năm gần đây, ứng dụng các kỹ thuật học máy (Machine Learning) phát hiện bất thường để bảo hệ, cảnh báo sớm cho các hệ thống IoT đã có những bước phát triển mạnh mẽ. Các mô hình học máy được huấn luyện trên tập dữ liệu bình thường và bất thường, sau đó được sử dụng để xây dựng một mô hình có khả năng phân loại và phát hiện các điểm bất thường trong dữ liệu. Tuy nhiên, việc phát triển các phương pháp phát hiện bất thường trên các hệ thống IoT đầy thách thức do một số yếu tố như:

- Dữ liệu không chuẩn: Dữ liệu từ các thiết bị IoT có thể không đồng nhất về cấu trúc và định dạng, điều này làm cho việc phát hiện bất thường trở nên phức tạp. Sự không thống nhất này có thể làm giảm hiệu suất của các thuật toán phát hiện bất thường.
- Sự thay đổi môi trường: Môi trường hoạt động của các thiết bị IoT thường thay đổi đột ngột, ví dụ như sự biến đổi thời tiết, nhiễu mạng, hoặc thậm chí là sự can thiệp từ con người. Những thay đổi này có thể tạo ra các bất thường không mong muốn trong dữ liệu.
- Sự thiếu hụt dữ liệu: Trong một số trường hợp, dữ liệu từ các thiết bị IoT có thể bị mất hoặc không đủ để đào tạo mô hình phát hiện bất thường. Sự thiếu hụt dữ liệu có thể làm giảm độ chính xác của quá trình phát hiện bất thường.
- Tính toán và tài nguyên hạn chế: Trong một số trường hợp, các thiết bị IoT có tính toán và tài nguyên hạn chế, làm cho việc triển khai các thuật toán

phức tạp để phát hiện bất thường trở nên khó khăn. Đòi hỏi sự tinh giản và tối ưu trong các giải pháp phát hiện bất thường.

- Tính đa dạng của dữ liệu IoT: Dữ liệu từ các loại thiết bị IoT khác nhau có thể đa dạng, bao gồm dữ liệu từ cảm biến, camera, bộ cảm biến và hệ thống điều khiển. Việc kết hợp và phân tích dữ liệu đa dạng này đòi hỏi các kỹ thuật phát hiện bất thường phức tạp và linh hoạt.

Thách thức về cập nhật và duy trì: Các thiết bị IoT thường được triển khai trong môi trường phức tạp và khó tiếp cận, làm cho việc cập nhật và duy trì các phần mềm và firmware trở nên khó khăn. Sự thiếu cập nhật có thể tạo ra các lỗ hổng bảo mật và làm giảm khả năng phát hiện bất thường.

### **1.3 Một số hệ thống phát hiện vận động bất thường**

#### ***1.3.1 Hệ thống phát hiện vận động bất thường trên thế giới***

Trong lĩnh vực nhận dạng hành động của con người, đặc biệt là trong việc phát hiện vận động bất thường (VĐBT), các cảm biến đóng vai trò then chốt. Chúng giúp theo dõi các chuyển động, điều kiện môi trường và các thông số khác từ xa. Dữ liệu từ cảm biến được truyền qua các giao thức phổ biến, đặc biệt là các giao thức không dây như Wi-Fi, Bluetooth...

Trên thế giới đang có nhiều những nghiên cứu về hệ thống hay các thiết bị để phát hiện vận động bất thường. Các cảm biến quán tính thường được gắn vào những vị trí cụ thể trên cơ thể như cổ tay (tích hợp trong đồng hồ thông minh), cổ chân (trong giày thông minh) hoặc thắt lưng (trong điện thoại thông minh). Cảm biến gia tốc có khả năng ghi nhận sự thay đổi vị trí của cơ thể và thường được kết hợp với con quay hồi chuyển để đo lường các chuyển động quay, hỗ trợ phục hồi tư thế [7]. Sự kết hợp giữa hai loại cảm biến này có thể nhận diện chính xác các hoạt động như đi lên/xuống cầu thang, ngồi, đi bộ, chạy hoặc nhảy [8]. Những thông tin này rất quan trọng trong việc phát triển các ứng dụng liên quan đến phục hồi chức năng, phân tích dáng đi, điều trị bệnh lý khớp, bệnh Parkinson và phát hiện ngã [9]. Ngoài ra, cảm biến gia tốc khi được tích hợp cùng cảm biến áp suất có thể tăng độ chính xác trong việc phát

hiện ngã hoặc các hoạt động di chuyển trên cầu thang [10]. Một loại cảm biến quán tính khác là từ kế, được sử dụng để xác định hướng di chuyển của cơ thể. Trong nghiên cứu [11], cảm biến từ kế đã được kết hợp với cảm biến gia tốc để phát hiện hành vi như xem TV, mang lại khả năng nhận diện chi tiết hơn.



**Hình 1.3. Thiết bị đồng hồ và dây đeo SureSafeGo**

Ngoài ra, hiện nay trên thị trường quốc tế đã xuất hiện một số hệ thống phát hiện vận động bất thường, đặc biệt là phát hiện ngã, được thương mại hóa. Tuy nhiên, để sử dụng các hệ thống này, người dùng không chỉ phải chi trả chi phí mua thiết bị ban đầu mà còn phải thanh toán thêm phí duy trì dịch vụ hàng tháng. Chẳng hạn, hệ thống phát hiện ngã SureSafeGO được trang bị SIM chuyên vùng tích hợp sẵn và GPS liên kết với Google Maps, cho phép xác định chính xác vị trí của người bị ngã. Thiết bị này còn hỗ trợ đàm thoại hai chiều, mang lại sự tiện lợi trong việc liên lạc khẩn cấp. Bộ cảnh báo cá nhân được trang bị nút nhấn SOS chuyên biệt. Người sử dụng sẽ nhấn một nút trên thiết bị để gọi Trung tâm trợ giúp SureSafe. Đối với hệ thống phát hiện ngã, người sử dụng không cần trực tiếp phải nhấn nút SOS để gọi trợ giúp. Cảm biến ngã sẽ tự động kích hoạt thiết bị liên lạc. Cảm biến hoạt động dựa trên sự thay đổi trong áp suất không khí, tốc độ chuyển động của người sử dụng và mọi tác động xảy ra khi ngã va chạm với mặt đất. Thiết bị có giá 149,95 bảng Anh (tương đương khoảng 4,5 triệu VNĐ), cùng với phí duy trì dịch vụ hàng tháng là 18,99 bảng Anh (khoảng 580 nghìn VNĐ/tháng).



**Hình 1.4. Thiết bị cảnh báo y tế Sentry**

Hệ thống cảnh báo y tế Sentry được phát triển bởi công ty BlueStar Senior Tech bao gồm một bộ được kết nối với bộ truyền thông cố định và dây đeo cho phép tự động chuyển tiếp cuộc gọi thoại khi có cảnh báo trong phạm vi khoảng 180m. Hệ thống cũng có cho phép người sử dụng giao tiếp hai chiều mà không cần đến điện thoại di động. Hệ thống phù hợp cho việc theo dõi và phát hiện ngã tại nhà có giá thuê bao hằng tháng là 29.95 USD/ tháng (khoảng 800 nghìn VNĐ/ tháng).



**Hình 1.5. Thiết bị đeo phát hiện ngã GreatCall Lively**

Hệ thống phát hiện ngã GreatCall Lively bao gồm một thiết bị có hình dạng giống mặt dây chuyền đeo ở cổ, giúp phát hiện và cảnh báo khi người sử dụng bị ngã. Khi phát hiện ngã, thiết bị sẽ kết nối với các trạm thu nhận và gửi cảnh báo đến các thành viên trong gia đình ngay lập tức. Điểm đặc biệt của hệ thống này là yêu cầu người dùng phải có điện thoại di động cài đặt ứng dụng GreatCall và kết nối qua

Bluetooth, với khoảng cách kết nối tối đa khoảng 10m. Khi người sử dụng bị ngã, thiết bị sẽ kích hoạt ứng dụng trên điện thoại để gọi và gửi vị trí của người bị ngã đến người thân hoặc người chăm sóc. Tuy nhiên, điểm hạn chế là hệ thống chỉ hoạt động khi điện thoại nằm trong vùng phủ sóng và thiết bị phải ở trong phạm vi kết nối Bluetooth. Hệ thống có giá 49,99 USD (tương đương 1,16 triệu VNĐ) và phí thuê bao hàng tháng là 14,99 USD (tương đương 350 nghìn VNĐ/tháng).



**Hình 1.6. Thiết bị phát hiện ngã Buddi**

Hệ thống phát hiện ngã Buddi hoạt động thông qua một vòng đeo tay kết nối với điện thoại di động qua ứng dụng Buddi Connect, cho phép người dùng điều chỉnh độ nhạy của việc phát hiện ngã trực tiếp từ ứng dụng. Giống như hệ thống GreatCall Lively, vòng đeo tay này sử dụng Bluetooth để kết nối với điện thoại. Khi phát hiện ngã, thiết bị có thể gửi cảnh báo đến người thân trong gia đình với chi phí khoảng 2 bảng mỗi tuần (khoảng 240 nghìn VNĐ/tháng), hoặc gửi cảnh báo đến trung tâm hỗ trợ 24/7 với mức phí 4 bảng mỗi tuần (khoảng 480 nghìn VNĐ/tháng).

Một hệ thống khác là Bay Alarm Medical, sử dụng một thiết bị hình mặt dây chuyền có khả năng phát hiện ngã và tự động gọi cảnh báo mà không cần sự can thiệp từ người dùng. Thiết bị có thể kết nối với trạm tiếp nhận trong bán kính 240m hoặc gọi sự trợ giúp từ chuyên gia qua kết nối 4G/LTE. Dịch vụ y tế của Bay Alarm có giá 19,95 USD mỗi tháng (khoảng 460 nghìn VNĐ), và có thể cao hơn nếu người dùng chọn thêm các dịch vụ hỗ trợ. Tuy nhiên, hệ thống này chỉ hỗ trợ người dùng tại Mỹ.

Các hệ thống trên đều không hỗ trợ người dùng tại Việt Nam, và chi phí sử dụng khá cao so với mức thu nhập trung bình ở đây. Do đó, cần phát triển một hệ thống phát hiện vận động bất thường (VĐBT), đặc biệt là ngã, có thể đáp ứng nhu cầu và khả năng tài chính của người dân Việt Nam.

**Bảng 1.1. So sánh các thiết bị phát hiện vận động bất thường đã được thương mại hóa**

Hệ thống phát hiện ngã	Ưu điểm	Nhược điểm
Sentry	<ul style="list-style-type: none"> <li>- Giá thành hợp lý</li> <li>- Đàm thoại hai chiều</li> <li>- Chế độ dẫn đường tới vị trí người bị ngã</li> <li>- Phạm vi sử dụng 800m</li> </ul>	<ul style="list-style-type: none"> <li>- Chỉ hỗ trợ tại Mỹ</li> <li>- Yêu cầu có kết nối điện thoại cố định</li> </ul>
SureSafe Go	<ul style="list-style-type: none"> <li>- Định vị GPS</li> <li>- Cảnh báo tự động</li> <li>- Giám sát 24/7</li> <li>- Phạm vi hoạt động lớn</li> <li>- Không yêu cầu kết nối cố định</li> </ul>	<ul style="list-style-type: none"> <li>- Cần sạc năng lượng thường xuyên</li> </ul>
Lively	<ul style="list-style-type: none"> <li>- Chi phí thấp</li> <li>- Kết nối điện thoại di động qua Bluetooth</li> </ul>	<ul style="list-style-type: none"> <li>- Phạm vi hoạt động khoảng 10m</li> <li>- Chỉ hỗ trợ tại Mỹ</li> </ul>
Buddi	<ul style="list-style-type: none"> <li>- Chi phí thấp</li> <li>- Điều khiển qua ứng dụng điện thoại</li> <li>- Có thể điều chỉnh độ nhạy cảm biến</li> </ul>	<ul style="list-style-type: none"> <li>- Cần sạc năng lượng thường xuyên</li> </ul>
Bay Alarm Medical	<ul style="list-style-type: none"> <li>- Thời gian sử dụng dài</li> <li>- Phạm vi hoạt động lớn, khoảng 244m</li> <li>- Có kết nối với điện thoại di động</li> </ul>	<ul style="list-style-type: none"> <li>- Chi phí khá đắt đỏ</li> <li>- Độc quyền sử dụng đàm thoại với AT&amp;T</li> </ul>

### ***1.3.2 Hệ thống phát hiện vận động bất thường ở Việt Nam***

Trong các công trình nghiên cứu về phát hiện vận động bất thường tại Việt Nam, mỗi công trình đều mang lại những đóng góp đáng kể, nhưng đồng thời cũng tồn tại những hạn chế cần khắc phục. Chẳng hạn, luận án “Phát hiện vận động bất thường (ngã) sử dụng cảm biến đeo” [1] đã tập trung vào việc sử dụng cảm biến đeo


để theo dõi vận động. Tuy nhiên, hệ thống này phụ thuộc nhiều vào vị trí đeo cảm biến, và việc đeo thiết bị liên tục trong thời gian dài có thể gây khó chịu cho người dùng. Thêm vào đó, hệ thống chủ yếu phát hiện các sự kiện ngã, chưa hỗ trợ đầy đủ cho các dạng vận động bất thường khác, dẫn đến tính ứng dụng chưa cao.

Tương tự, các nghiên cứu sử dụng camera để phát hiện vận động bất thường tuy mang lại độ chính xác cao trong phân tích hành vi nhưng lại dễ bị ảnh hưởng bởi điều kiện ánh sáng, vật cản, và góc quay camera. Quan trọng hơn, việc sử dụng camera cũng đặt ra vấn đề nghiêm trọng về quyền riêng tư, đặc biệt trong các không gian cá nhân hoặc chăm sóc y tế. Những yếu tố này khiến giải pháp này khó được chấp nhận trong nhiều môi trường thực tế.

Phòng thí nghiệm phân tích vận động Motion Lab tại Vinmec mang tính hiện đại và có khả năng đo lường chi tiết các chuyển động, nhưng lại giới hạn phạm vi ứng dụng trong môi trường phòng thí nghiệm. Chi phí triển khai và bảo trì cao cũng là rào cản lớn khiến hệ thống này khó mở rộng hoặc triển khai ở các cơ sở y tế quy mô nhỏ hoặc vùng nông thôn.

Hệ thống đề xuất trong đề án khắc phục hiệu quả những nhược điểm này. Bằng cách tối ưu hóa các mô hình học sâu để phù hợp với phần cứng nhỏ gọn và tài nguyên hạn chế, hệ thống có thể triển khai dễ dàng trên các thiết bị đeo hoặc các nút IoT. Đồng thời, hệ thống này không gây xâm phạm quyền riêng tư như các giải pháp dựa trên camera và vẫn duy trì khả năng hoạt động ổn định ngay cả trong môi trường phức tạp. Đây là lợi thế vượt trội, giúp giải pháp trở thành một lựa chọn tối ưu cho nhiều ứng dụng trong y tế, chăm sóc sức khỏe, và các lĩnh vực khác.

#### **1.4 Dữ liệu cảm biến cho nhận dạng hoạt động ở người**



**Hình 1.7. Các loại dữ liệu cảm biến từ những bộ phận cơ thể người khác nhau**

Chăm sóc sức khỏe sử dụng cảm biến trên cơ thể người nhận được sự quan tâm lớn từ các nhà nghiên cứu bởi ứng dụng thực tiễn của chúng như hệ thống chăm sóc sức khỏe thông minh. Trong lĩnh vực nhận dạng hoạt động ở người nói chung và phát hiện VDBT nói riêng, cảm biến có vai trò như một trình điều khiển rất quan trọng, cảm biến giúp theo dõi chuyển động, môi trường và các thông số khác từ xa, dữ liệu từ cảm biến được truyền qua các giao thức thông dụng, đặc biệt là các giao thức không dây như WiFi, Bluetooth... Mặc dù có rất nhiều cách khác nhau để cảm biến có thể nhận dạng hoạt động, cách đơn giản nhất là chúng có thể đeo được trên cơ thể người.

Cảm biến ngày càng trở thành phần không thể thiếu trong các thiết bị và đồ vật mà con người sử dụng hàng ngày. Những tiến bộ vượt bậc trong công nghệ chế tạo cảm biến đã tạo ra các thiết bị nhỏ gọn, tiết kiệm năng lượng và có độ bền cao, ít bị ảnh hưởng bởi các yếu tố môi trường. Đặc biệt, khả năng kết nối không dây và giá thành ngày càng giảm khiến cho cảm biến trở nên phổ biến hơn, thường được tích hợp trong các thiết bị thông minh để thu thập dữ liệu và hỗ trợ các chức năng tương tác khi người dùng di chuyển. Các cảm biến đeo đang được phát triển để dễ dàng mang theo và sử dụng trong thời gian dài mà không gây bất tiện, từ đó mở rộng các ứng dụng trong nhận dạng hoạt động và chăm sóc sức khỏe.



Trong số các cảm biến được sử dụng phổ biến trong việc nhận diện hoạt động và phát hiện vận động bất thường (VĐBT), cảm biến quán tính (gồm gia tốc kế, con quay hồi chuyển và cảm biến từ trường) là những lựa chọn nổi bật. Các cảm biến này có ưu điểm về kích thước nhỏ gọn và dễ dàng tích hợp vào các thiết bị như đồng hồ thông minh, giày thông minh, hay các thiết bị đeo khác, giúp người dùng theo dõi chuyển động liên tục. Tuy nhiên, chúng cũng gặp phải một số hạn chế như tiêu thụ năng lượng và độ nhạy cảm cao với chuyển động cơ thể, đôi khi dẫn đến nhận dạng sai các hoạt động. Khi được kết hợp với các cảm biến khác như con quay hồi chuyển và cảm biến áp suất, khả năng nhận diện các hoạt động như đi bộ, chạy, lên/xuống cầu thang, hay ngã sẽ chính xác hơn.

Cảm biến hình ảnh cũng là một công nghệ hữu ích trong việc ghi lại hoạt động của người sử dụng, như các thiết bị SenseCam hay Microsoft Kinect. Những thiết bị này có thể thu thập dữ liệu về các hoạt động hằng ngày, bao gồm việc ngã, và cung cấp thông tin vị trí để hỗ trợ chăm sóc người cao tuổi. Tuy nhiên, việc sử dụng cảm biến hình ảnh trong chăm sóc sức khỏe vẫn gặp phải thách thức lớn về bảo mật, quyền riêng tư và khả năng lưu trữ dữ liệu.

Ngoài ra, các cảm biến môi trường như cảm biến nhiệt độ, độ ẩm, hay cảm biến chấn động cũng đóng vai trò quan trọng trong các nghiên cứu về nhà thông minh và bệnh viện thông minh, mặc dù ít được áp dụng trong bài toán phát hiện VĐBT. Một số nghiên cứu còn thử nghiệm cảm biến sợi quang và cảm biến đo áp lực để phát hiện các cơn co thắt cơ bắp, nhưng chúng không được sử dụng rộng rãi trong lĩnh vực phát hiện VĐBT.

Cảm biến lai là một lựa chọn mới trong các thiết bị đeo thương mại, như cảm biến kết hợp gia tốc và GPS, giúp theo dõi chuyển động của người dùng. Các thiết bị như đồng hồ thông minh Apple Watch cũng đã tích hợp khả năng phát hiện ngã. Tuy nhiên, những thiết bị này có giá thành cao và yêu cầu đồng bộ với các thiết bị khác trong hệ sinh thái của nhà sản xuất, điều này làm hạn chế khả năng tiếp cận với người dùng ở Việt Nam.

Mặc dù công nghệ cảm biến đã có những bước tiến đáng kể, nhưng vẫn còn những thách thức cần giải quyết. Dù kích thước của cảm biến ngày càng nhỏ gọn, chúng vẫn có thể gây bất tiện khi theo dõi lâu dài trên cơ thể người dùng. Các thiết bị đeo thương mại hiện tại chủ yếu phục vụ cho các hoạt động thể thao, còn các thiết bị phát hiện VDBT vẫn còn ít, đặc biệt là ở Việt Nam. Dữ liệu thu thập từ các cảm biến đôi khi bị nhiễu, và các vấn đề về pin và môi trường cũng ảnh hưởng đến hiệu quả của hệ thống. Do đó, việc xử lý và xác thực dữ liệu vẫn là một bài toán thách thức trong lĩnh vực này.

Để có sự đánh giá khách quan và chính xác của giải pháp trong đề tài phát hiện vận động bất thường, phần này sẽ trình bày sơ lược về tập dữ liệu được sử dụng cho đề tài phát hiện vận động bất thường sử dụng cảm biến trong thiết bị đeo.

### **1.5 Kết luận chương 1**

Trong chương 1 đã đưa ra một cái nhìn tổng quan về bài toán phát hiện vận động bất thường, một chủ đề đang thu hút nhiều sự quan tâm trong lĩnh vực IoT. Đầu tiên, đề án đã giới thiệu về khái niệm và tầm quan trọng của việc phát hiện các hoạt động bất thường, đặc biệt trong bối cảnh các hệ thống tự động và thông minh. Việc nhận dạng và phát hiện kịp thời các bất thường giúp ngăn chặn các rủi ro và bảo vệ an toàn cho con người và tài sản. Đề án cũng đã nêu ra các thách thức kỹ thuật trong việc phát hiện bất thường, như sự đa dạng của dữ liệu, các yếu tố môi trường, cũng như yêu cầu về hiệu suất cao trong các hệ thống IoT. Tiếp theo, tổng quan về các cảm biến đã được trình bày, giúp hiểu rõ hơn về các công nghệ có thể sử dụng để nhận dạng hoạt động con người. Cuối cùng, đề án nghiên cứu đã xem xét một số hệ thống phát hiện bất thường đã được thương mại hóa, cùng với việc thảo luận về tập dữ liệu được sử dụng trong các nghiên cứu và ứng dụng thực tế. Các kiến thức này sẽ làm nền tảng cho các chương sau, nơi đề án đi sâu vào các phương pháp và kỹ thuật phát hiện bất thường cụ thể hơn.

## **CHƯƠNG 2 – NGHIÊN CỨU THUẬT TOÁN VÀ CẢM BIẾN PHÁT HIỆN VẬN ĐỘNG BẤT THƯỜNG ỨNG DỤNG MÔ HÌNH HỌC MÁY**

### **2.1 Giới thiệu chung**

Trong những năm gần đây sự phát triển vượt bậc của học máy (ML) đã mở ra nhiều hướng nghiên cứu mới và ứng dụng được vào nhiều lĩnh vực khác nhau. Một trong những ứng dụng quan trọng đó là phát hiện bất thường trên các dữ liệu. Sử dụng học máy có thể giải quyết được thách thức của việc xử lý lượng dữ liệu lớn và phức tạp từ các hệ thống IoT. Cụ thể, các thuật toán học máy có khả năng tự động phân tích dữ liệu từ các cảm biến trên các thiết bị đeo, giúp tự động hóa quá trình phát hiện sự bất thường. Lợi thế của việc ứng dụng học máy (ML) vào phát hiện bất thường trong hoạt động nằm ở việc có khả năng phân tích và xử lý lượng dữ liệu lớn, giúp tăng cường khả năng phát hiện các sự bất thường một cách chính xác và hiệu quả nhất. Ngoài ra, nếu kết hợp học máy (ML) vào các hệ thống IoT và thực hiện xử lý tại biên còn giúp xử lý dữ liệu tại chỗ trước khi truyền đến trung tâm. Điều này giúp giảm bớt gánh nặng cho hạ tầng mạng và giảm độ trễ trong việc đưa ra các quyết định quan trọng. Bằng cách phát hiện và xử lý các dữ liệu không bình thường ngay tại điểm thu thập, hệ thống có thể tự động áp dụng các biện pháp bảo vệ người sử dụng hoặc thông báo cảnh báo mà không cần phải chờ đợi phản hồi từ trung tâm. Điều này đặc biệt hữu ích trong các ứng dụng đòi hỏi phản ứng nhanh, nơi mà mỗi giây đều quan trọng và mọi sự cố đều cần được xử lý ngay lập tức để tránh gây ra các hậu quả không mong muốn về người. Tuy nhiên, thách thức lớn nhất đối với việc triển khai các thuật toán học máy (ML) vào các hệ thống IoT tại biên (được sử dụng để mô tả các thiết bị và cảm biến tương tác với dữ liệu thời gian thực so với khả năng kết nối mạng) là sự hạn chế về tài nguyên của các nút IoT. Thường thì các nút IoT được tích hợp từ các cảm biến có hạn chế về tài nguyên và được sử dụng cùng với các hệ thống nhúng có chi phí thấp. Các thuật toán học máy thường đòi hỏi khá nhiều tài nguyên tính toán và bộ nhớ để thực hiện quá trình huấn luyện và dự đoán. Tuy nhiên, các nút

IoT thường chỉ có khả năng xử lý và lưu trữ hạn chế, điều này có thể làm giảm hiệu suất và độ chính xác của các thuật toán học máy khi triển khai trên các hệ thống IoT tại biên. Để vượt qua thách thức này, cần phải phát triển các phương pháp tiên tiến để tối ưu hóa việc triển khai thuật toán học máy trên các nút IoT, bao gồm cả việc tối ưu hóa thuật toán và quản lý tài nguyên hiệu quả.

Để khắc phục các hạn chế về tài nguyên và triển khai hiệu quả các thuật toán học máy trên các hệ thống IoT tại biên. Đề án sẽ nghiên cứu và triển khai một mô hình học máy có thể phân biệt được các bất thường đối với các hoạt động thường của con người. Ứng dụng một số thuật toán như CNN và DNN để phân loại các sự cố bất thường dựa trên tập dữ liệu thu được từ các cảm biến trên thiết bị

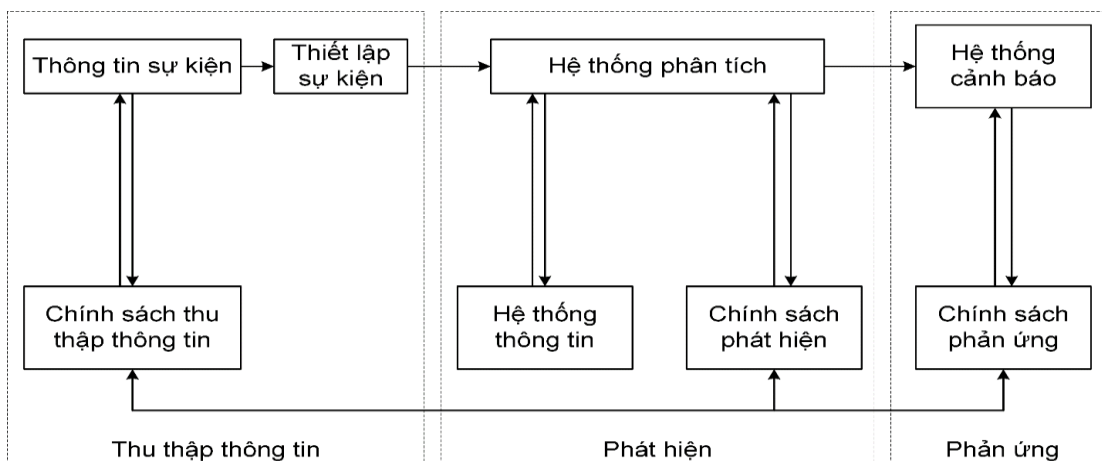
## **2.2 Sơ đồ tổng quát hệ thống phát hiện vận động bất thường**

Sơ đồ tổng quát của hệ thống phát hiện VDBT được thể hiện trong Hình 2.1. Một hệ thống phát hiện bất thường cơ bản hoạt động theo ba giai đoạn chính là: thu thập thông tin, phát hiện và phản ứng. Trong giai đoạn thu thập thông tin, dữ liệu được thu thập hoặc theo dõi từ cảm biến, nhật ký hoạt động của hệ thống hoặc các loại dữ liệu hoạt động khác. Các chính sách thu thập thông tin đại diện cho loại dữ liệu được thu thập, tần số lấy mẫu và điều kiện để kích hoạt bộ thu. Trong giai đoạn phát hiện, một khi dữ liệu được thu thập và biến đổi thành một sự kiện, hệ thống bắt đầu quá trình phân tích mẫu dữ liệu này theo chính sách phát hiện được cài đặt trong hệ thống. Chính sách phát hiện là yếu tố chính để phân loại một hệ thống phát hiện bất thường, chính sách được sử dụng có thể là các luật được cài đặt cứng hay các thuật toán để xác định đặc trưng của dữ liệu, từ đó đưa ra quyết định xem dữ liệu đó là bình thường hay bất thường. Cuối cùng, giai đoạn Phản ứng tiếp nhận kết quả và đưa ra những cảnh báo kịp thời cho người sử dụng hoặc trung tâm quản lý.

Như đã đề cập bên trên, để có thể phân loại một hệ thống phát hiện bất thường, ta có thể sử dụng phương thức cũng như chính sách khi phân tích một mẫu dữ liệu, từ đó ta chia hệ thống phát hiện bất thường theo hai hướng:

- Sử dụng các phương pháp truyền thống: Thuật toán phát hiện vận động bất thường truyền thống như sử dụng các thuật toán thống kê, phương pháp quyết định cứng (hoặc theo ngưỡng)...
- Sử dụng phương pháp thông minh: Thuật toán phát hiện vận động bất thường thông minh sử dụng mô hình học máy.

Các hệ thống phát hiện bất thường truyền thống bao gồm những phương pháp không sử dụng các thuật toán học máy hay học sâu phức tạp. Chúng thường áp dụng các mô hình thống kê, hệ thống dựa trên quy tắc, hoặc các kỹ thuật dựa trên khoảng cách để phát hiện các điểm bất thường. Những phương pháp này thường dễ triển khai và tiết kiệm tài nguyên tính toán hơn so với các phương pháp học máy hiện đại, nên rất phù hợp cho các tập dữ liệu nhỏ hoặc các tình huống ít phức tạp. Trái lại, các hệ thống phát hiện điểm bất thường thông minh sử dụng các kỹ thuật tiên tiến, thường bao gồm học máy (ML), học sâu (DL) và trí tuệ nhân tạo (AI), để nhận diện các điểm bất thường phức tạp và tinh vi. Khác với các hệ thống truyền thống, các hệ thống này có khả năng tự điều chỉnh, dựa trên dữ liệu và có thể xử lý các môi trường phức tạp, liên tục thay đổi. Những hệ thống này ngày càng quan trọng trong các lĩnh vực như an ninh mạng, tài chính, IoT và chăm sóc sức khỏe, nơi việc phát hiện các điểm bất thường theo thời gian thực là rất quan trọng.




**Hình 2.1. Mô hình hệ thống phát hiện bất thường**

## **2.3 Thuật toán phát hiện vận động bất thường truyền thống**

### **2.3.1 Phương pháp thống kê**

Phương pháp thống kê là một phương pháp dựa trên mô hình, trong đó mô hình được tạo từ những dữ liệu và đối tượng và mối tương quan lẫn nhau giữa chúng. Hầu hết sử dụng phương pháp thống kê trong phát hiện bất thường đều dựa trên quá trình phát triển một mô hình phân bố xác suất và khả năng xuất hiện của đối tượng đối với mô hình xác suất đó. Trong phương pháp thống kê, một dữ liệu bất thường (hay còn gọi là ngoại lai) là một đối tượng có khả năng xuất hiện thấp. Nếu giả sử dữ liệu tuân theo phân bố Gauss, giá trị trung bình và độ lệch chuẩn của phân bố xác suất có thể được tính toán trực tiếp từ dữ liệu.

Phân bố Gauss, hay còn gọi là phân bố chuẩn là một trong những phân bố xác suất điển hình nhất trong thống kê. Phân bố Gauss gồm hai tham số chính là: giá trị trung bình  $\mu$  và độ lệch chuẩn  $\sigma$ , ký hiệu là  $N(\mu, \sigma)$ .



**Hình 2.2. Hàm mật độ xác suất (PDF) trong phân bố Gauss**

Khả năng rất thấp khi mà một đối tượng hoặc dữ liệu trong phân bố  $N(0,1)$  sẽ nằm ở hai đầu của phân phối. Ví dụ, xác suất chỉ là 0.0027 rằng một đối tượng nằm ngoài khu vực trung tâm giữa  $\pm 3$  độ lệch chuẩn. Tóm lại, nếu  $c$  là một hằng số và  $x$  là giá trị thuộc tính của một đối tượng, thì xác suất  $|x| \geq c$  sẽ giảm nhanh khi  $c$  tăng lên. Giả sử  $\alpha$  là giá trị xác suất khi  $|x| \geq c$ . Bảng dưới đây hiển thị một số giá trị mẫu cho  $c$  và các giá trị tương ứng cho  $\alpha$  khi phân phối là  $N(0,1)$ .

**Bảng 2.1. Một số giá trị xác suất của phân bố Gauss theo giá trị  $c$**

$c$	$\alpha$
1.00	0.3173

1.50	0.1336
2.00	0.0455
2.50	0.0124
3.00	0.0027
3.50	0.0005
4.00	0.0001

Để xác định điểm giá trị bất thường hay không, nếu ta sử dụng giá trị  $c$  so với tâm của phân bố thì giá trị xác suất của giá trị  $c$  là một tiêu chí đánh giá khả năng bất thường của điểm dữ liệu này. Bất thường phân bố Gauss được tính dữ liệu tuân theo phân bố  $N(\mu, \sigma)$ , một đối tượng có thuộc tính trong phân bố là  $x$  là bất thường nếu  $|x| \geq c$ , với  $c$  là một hằng số được chọn khi  $P(|x| \geq c) = \alpha$ .

Để sử dụng định nghĩa ở trên, xác định một giá trị cho  $\alpha$  là cần thiết. Các đối tượng bất thường cho thấy một giá trị từ một phân phối khác biệt,  $\alpha$  biểu thị xác suất mà chúng ta vô tình phân loại một đối tượng từ phân phối cho trước là một ngoại lệ. Nếu một ngoại lệ là một giá trị hiếm gặp của phân phối  $N(0,1)$ , thì  $\alpha$  đại diện cho mức độ hiếm có của giá trị đó. Bây giờ, nếu phân phối của một thuộc tính quan tâm đối với các đối tượng bình thường có phân phối Gaussian với trung bình là  $\mu$  và độ lệch chuẩn là  $\sigma$ , tức là phân phối  $N(\mu, \sigma)$ , thì để sử dụng định nghĩa đã đề cập ở trên, ta phải chuyển đổi thuộc tính  $x$  thành một thuộc tính mới  $t$ , có phân phối  $N(0,1)$ . Cụ thể, ta thiết lập  $t = \frac{x-\mu}{\sigma}$  ( $t$  thường được gọi là  $t$ -score). Ở đây,  $\mu$  và  $\sigma$  là không xác định và được ước tính bằng cách sử dụng trung bình mẫu và độ lệch chuẩn mẫu  $S_x$ . Trên thực tế, phương pháp này hoạt động tốt khi kích thước dữ liệu lớn. Tuy nhiên, chúng ta lưu ý rằng phân phối của  $z$  thực ra không hoàn toàn là  $N(0,1)$ .

### **2.3.2 Phương pháp dựa trên khoảng cách**

Từ định nghĩa, việc xác định một đối tượng bất thường là tìm ra điểm dữ liệu khác biệt so với những điểm còn lại. Một trong những phương pháp phổ biến và đơn giản nhất là tính toán được khoảng cách giữa từng điểm và tập hợp các điểm. Ý tưởng chính trong phương pháp này là những điểm dữ liệu bất thường thông thường có vị trí tách biệt ra khỏi một tập, một nhóm dữ liệu khác. Đây là một công cụ mạnh mẽ để phát hiện các mô hình bất thường trong các lĩnh vực khác nhau như an ninh mạng, tài

chính, chăm sóc sức khỏe và giám sát công nghiệp. Tuy nhiên, điều chỉnh cẩn thận các tham số (như số lượng lân cận hoặc ngưỡng khoảng cách) và có thể cần tính toán chuyên sâu cho các tập dữ liệu lớn là vô cùng cần thiết. Bất chấp những thách thức này, các thuật toán dựa trên khoảng cách vẫn là một lựa chọn phổ biến do tính linh hoạt và hiệu quả của chúng trong các nhiệm vụ phát hiện sự bất thường trong thế giới thực.

Giả sử  $\mathcal{D}$  đại diện cho tập dữ liệu  $n$ -chiều, trong không gian liên tục không giới hạn  $\mathcal{R}^n$ . Những điểm dữ liệu trong  $\mathcal{D}$  được ký hiệu là  $p, q$ , và  $d(p, q)$  là khoảng cách giữa hai điểm dữ liệu tương ứng.

Bắt đầu với một thuật toán dựa trên khoảng cách đơn giản nhất, ta cần làm rõ ba vấn đề chính sau:

1. Phương pháp đo: Cho biết mức độ bất thường của điểm dữ liệu. Cách thức tính toán khoảng cách giữa hai điểm dữ liệu là gì?
2. Khẳng định: Kết quả điểm dữ liệu có phải bất thường hay không? Có thể xác định một giá trị ngưỡng nhằm làm tiêu chí cho mức độ bất thường của điểm dữ liệu.
3. Tương quan: Điểm dữ liệu này có “bất thường hơn” điểm dữ liệu kia hay không?

Các phép đo độ tương tự phổ biến bao gồm các phép đo trực tiếp như khoảng cách Euclid, Minkowski và Mahalanobis. Ngoài ra, các phép đo khác như độ tương đồng cosine và chỉ số Jaccard cũng được sử dụng; thường thì các phép đo gián tiếp, chẳng hạn như Lân cận gần nhất chung (SNN), lại phù hợp hơn.

$$d_{Mahalanobis} = \sqrt{(p - q)^T S^{-1} (p - q)} \quad (2.1)$$

$$d_{Minkowski} = \min_{i=1}^d |p_i - q_i| \quad (2.2)$$

$$d_{Euclid} = \sqrt{\sum_{i=1}^d (p_i - q_i)^2} \quad (2.3)$$



Thuật toán đơn giản nhất khi sử dụng khoảng cách giữa các điểm dữ liệu dựa trên sử dụng giả định về phân bố dữ liệu, tức là dữ liệu là một chiều và được phân bố chuẩn với giá trị trung bình  $\mu$  và độ lệch chuẩn  $\sigma$ . Khoảng cách với tâm phân bố càng lớn đồng nghĩa với khả năng xuất hiện của điểm dữ liệu đó càng thấp. Bởi vì có xác suất thấp nên điểm có khoảng với tâm phân bố lớn như vậy có khả năng trở thành một đối tượng bất thường. Một cách cụ thể hơn, khi giá trị  $z$  tăng, số lượng điểm dữ liệu tại khoảng cách  $z\sigma$  so với tâm  $\mu$  giảm nhanh chóng. Ví dụ chỉ khoảng 0.1% điểm dữ liệu vượt quá  $\mu + 3\sigma$ , và có thể áp dụng điều này để điều chỉnh tiêu chí bất thường cho điểm dữ liệu: Nếu một điểm dữ liệu  $z$  càng lớn nghĩa là càng cách xa so với tâm của phân bố (trung bình), thì đó là điểm bất thường.

Trong các phần trước, số lượng điểm dữ liệu trong một bán kính cố định đã được sử dụng để xác định mức độ bất thường. Tuy nhiên, có thể lập luận rằng một điểm là bất thường nếu các lân cận của nó ở rất xa hay nó cách xa các lân cận của nó. Nghĩa là, một tiêu chí độ ngoại lệ có thể được mô tả dựa trên khoảng cách đến các lân cận của nó. Trong nghiên cứu của Ramaswamy và cộng sự, khoảng cách k-NN (k-Nearest Neighbors) của một điểm được sử dụng làm điểm số ngoại lệ của nó. Giả sử lân cận gần nhất thứ  $k$  của một điểm  $p$  được ký hiệu là  $NN(p, k)$ , và tính khoảng cách  $d(p, NN(p, k)) = d_k(p)$ . Giá trị  $d_k(p)$  càng lớn cho thấy rằng  $p$  có độ bất thường càng cao. Các giá trị  $d_k(p)$  được xếp theo thứ tự giảm dần và các điểm tương ứng với các giá trị cao nhất sẽ được coi là bất thường. Mô tả chi tiết về thuật toán này được trình bày trong Thuật toán “k-NN outlier”.

---

Thuật toán: k-NN

---

Đầu vào:  $k, n, \mathcal{D}$ .

Đầu ra: Tập  $O$  gồm  $n$  điểm dữ liệu bất thường.

1. Xét  $O = \emptyset$ .
  2. Với mỗi  $p \in \mathcal{D}$ :
  3.    $N_p = \emptyset$
  4.    $\forall q \in \mathcal{D} \mid q \neq p$ :
  5.       Nếu  $|N_p| < k$  thì:
  6.           Thêm  $q$  vào  $N_p$
  7.       không:
-

- 
8. Nếu  $\max(d(p, s) | s \in N_p) > d(p, q)$  thì:
  9. Thêm  $q$  vào  $N_p$  và loại bỏ  $s$ .
  10.  $NN(p, k) = \max(d(p, s) | s \in N_p)$
  11. Với mỗi  $p \in \mathcal{D}$ :
  12. Nếu  $|O| < k$  thì:
  13. Thêm  $p$  vào  $O$
  14. không:
  15. Nếu  $\min(NN(s, k) | s \in O) < NN(s, k)$  thì:
  16. Thêm  $p$  vào  $O$  và loại bỏ  $s$
  17. Kết thúc.
- 

Angiulli và Pizzuti [1] cho rằng tiêu chí xác định ngoại lệ của Ramaswamy và cộng sự không mang lại kết quả tốt, đặc biệt khi  $\mathcal{D}$  chứa nhiều cụm có mật độ khác nhau. Họ đề xuất rằng một thước đo ngoại lệ phù hợp hơn là trọng số của  $p$  được định nghĩa như sau:

$$\sum_{i=1}^k d_i(p)$$

Như bên trên, các giá trị trọng số này được sắp xếp theo thứ tự giảm dần để tìm ra các điểm bất thường nhất

## 2.4 Thuật toán phát hiện vận động bất thường thông minh sử dụng mô hình học máy

Thuật toán phát hiện vận động bất thường thông minh sử dụng mô hình học máy là phương pháp áp dụng các mô hình học máy tiên tiến để phân tích và nhận diện các hành vi thông qua dữ liệu đầu vào. Dữ liệu này thường được gán nhãn, phân loại thành các hoạt động bình thường (như đi bộ, ngồi, chạy) và bất thường (như ngã, trượt chân, hoặc các hành vi nguy hiểm khác). Mục tiêu của thuật toán là “học” từ những đặc trưng quan trọng trong dữ liệu để phát hiện chính xác các hành vi bất thường. Quá trình này bao gồm huấn luyện mô hình với các tập dữ liệu được chuẩn bị trước, sau đó áp dụng mô hình đã học để phân tích dữ liệu mới trong thời gian thực, từ đó đưa ra cảnh báo hoặc hành động phù hợp.

Mô hình học máy là một lĩnh vực nghiên cứu rộng lớn với nhiều ứng dụng khác nhau, trong đó có phát hiện vận động bất thường. Thông thường, nó được phân thành ba nhóm chính: học có giám sát (supervised learning), học không giám sát

(unsupervised learning) và học tăng cường (RL - Reinforcement Learning). Tuy nhiên, cũng có những sự kết hợp khác như học bán giám sát (semi-supervised learning). Hơn nữa, với những tiến bộ về công nghệ, học sâu (deep learning) cũng đang ngày càng phát triển mạnh mẽ. Nhiều kỹ thuật học máy thường áp dụng phương pháp học sâu hoặc được kết hợp với học sâu để cải thiện hiệu quả.

- Học có giám sát: mô hình hóa cả dữ liệu bình thường và bất thường, yêu cầu dữ liệu được gán nhãn chi tiết.
- Học không giám sát: xác định bất thường mà không cần biết trước về chi tiết dữ liệu đầu vào.
- Học bán giám sát: chỉ dữ liệu bình thường được mô hình hóa, dữ liệu bất thường được xác định bởi giá trị ngưỡng khác với bình thường.

Học có giám sát liên quan tới kỹ thuật học máy huấn luyện một mô hình, trong đó áp dụng một tập dữ liệu tham khảo cho đầu ra tương ứng. Ứng dụng học có giám sát trong phát hiện bất thường có một số trở ngại so với các mục đích ứng dụng học có giám sát khác. Trong thực tiễn, những dữ liệu mẫu hiếm gặp thường xuất hiện ít hơn trong quá trình huấn luyện. Ta có thể tùy chỉnh thuật toán cho trường hợp mất cân bằng dữ liệu như ở trên, từ đó tăng mức độ ảnh hưởng của những dữ liệu bất thường đối với mô hình. Phổ biến nhất là sử dụng phương pháp học có giám sát theo trọng số. Dữ liệu huấn luyện có thể được tái gán nhãn theo trọng số. Kỹ thuật học có giám sát thể hiện độ tin cậy cao nhờ vào việc “sự thật nền tảng” được đại diện bởi dữ liệu đã được gán nhãn trước. Tuy nhiên, trong nhiều hệ thống thực tế, thông tin này chỉ có sẵn một phần hoặc hoàn toàn không có. Việc giới thiệu các phương pháp học bán giám sát và không giám sát đã giúp khắc phục nhược điểm này.

Học bán giám sát có đôi nét tương đồng với học có giám sát, nhưng nó chỉ cần một số ít dữ liệu đã được gán nhãn trước, phần dữ liệu còn lại hoàn toàn không được gán nhãn. Bởi vì không được gán nhãn một cách tường minh, loại dữ liệu này có thể thu thập được từ thế giới thực thông qua một số thủ tục hoặc tách rời khỏi dữ liệu bình thường trong một lượng lớn dữ liệu. Mặc dù học bán giám sát là lựa chọn tốt nhất khi chỉ có một lượng nhỏ dữ liệu được gán nhãn, nhưng phương pháp này vẫn

tồn tại một số hạn chế do các giả định liên quan đến việc sử dụng dữ liệu chưa gán nhãn. Những giả định này dựa trên mối quan hệ giữa nhãn và phân phối của dữ liệu chưa gán nhãn, do đó các giả định sai có thể dẫn đến hiệu suất kém.

Ngược lại với hai phương pháp trên là học không giám sát, học không giám sát học từ dữ liệu mà đầu ra tương ứng của nó không được biết trước. Với học không giám sát, không cần đến tiền gán nhãn dữ liệu cho mô hình học máy, giảm thiểu đáng kể chi phí triển khai. Nguyên lý hoạt động cơ bản của học không giám sát dựa trên giả định rằng dữ liệu bất thường hiếm khi xuất hiện và khác biệt hoàn toàn so với phần còn lại. Thuật toán phổ biến là phân cụm, trong đó dữ liệu bất thường không thuộc bất kỳ một cụm nào hoặc cụm đó chỉ là thiểu số so với nhiều cụm còn lại. Nhược điểm chung của ba phương pháp trên là khả năng thích ứng với thay đổi thấp, trừ khi mô hình nhận được sự can thiệp từ bên ngoài. Do đó, những phương pháp như học tăng cường hay học sâu xuất hiện như một giải pháp vô cùng hiệu quả cho hầu hết các bài toán.

Một cách tiếp cận khi học từ những sự tương tác, được gọi là học tăng cường, đây là phương pháp tương đồng nhất đối với quá trình học của con người, tập trung vào việc ánh xạ hành động và từng tình huống để đạt được kết quả tối ưu nhất. Thành phần chính trong mô hình học tăng cường được gọi là một đối tượng phần mềm có thể thực hiện hành động và môi trường bao quanh đối tượng đó. Trạng thái của môi trường bị ảnh hưởng bởi những hành động, hành vi gây ra bởi đối tượng phần mềm. Trong học tăng cường tồn tại một giá trị gọi là giá trị thưởng, mục tiêu chính là tối đa hóa giá trị thưởng đạt được trong suốt quá trình hoạt động của mô hình. Điểm khác biệt của học tăng cường so với các loại hình học khác là sự độc lập với giám sát và tập trung vào việc ra quyết định nhằm đạt được một mục tiêu cụ thể. Học tăng cường thường được sử dụng trong các kịch bản IoT (Internet of Things) với môi trường đa tác nhân. Nó có thể được áp dụng để tạo ra một hệ thống có khả năng thích nghi với môi trường xung quanh.

Cuối cùng là học sâu, học sâu (deep learning) được phát triển từ mạng nơ-ron nhân tạo truyền thống (ANN). Về mặt kiến trúc, điểm khác biệt của học sâu là các

lớp ẩn có chiều sâu hơn so với các ANN truyền thống, vốn chỉ có vài lớp ẩn (mạng nông). Các lớp bổ sung này cho phép học sâu có khả năng học từ một lượng lớn dữ liệu. Một sự khác biệt khác là trong các mô hình học máy truyền thống, các đặc trưng (features) thường được trích xuất thủ công từ dữ liệu đầu vào trước khi đưa vào mạng để tiến hành quá trình học. Trong học sâu, các đặc trưng của dữ liệu đầu vào được tự động học qua nhiều lớp mạng. Học sâu có thể được áp dụng theo cả phương pháp có giám sát (supervised) và không giám sát (unsupervised). Các nghiên cứu gần đây đã áp dụng học sâu để phát hiện bất thường trong các hệ thống cảm biến. Nhiều loại mạng học sâu đã được đề xuất như mạng nơ-ron Tích chập (CNN), mạng nơ-ron sâu (DNN) và mạng nơ-ron hồi quy (RNN).

#### ***2.4.1 Một số mô hình mạng nơ-ron***

Mạng nơ-ron nhân tạo (ANN) đã trở thành công cụ mạnh mẽ trong nhiều bài toán học máy, từ nhận dạng hình ảnh đến dự đoán hành vi. Các mô hình mạng nơ-ron có khả năng học và trích xuất đặc trưng từ dữ liệu, giúp nhận diện các mẫu và hành vi. Trong đó, mỗi loại mạng nơ-ron có những ưu nhược điểm riêng khi áp dụng vào các bài toán khác nhau.

Mạng nơ-ron hồi tiếp (Recurrent Neural Network - RNN) là một sự mở rộng của mạng nơ-ron truyền thống, được thiết kế đặc biệt để xử lý dữ liệu theo chuỗi hoặc tuần tự. Cấu trúc của RNN bao gồm các thành phần chính như: đầu vào, đơn vị ẩn và đầu ra, trong đó các đơn vị ẩn có chức năng lưu trữ thông tin, giống như bộ nhớ. Mỗi đơn vị trong mạng RNN sử dụng cả đầu vào hiện tại và đầu ra từ các bước trước để đưa ra quyết định. RNN được ứng dụng rộng rãi trong nhiều lĩnh vực, bao gồm nhận diện giọng nói, phân tích hoạt động của con người, dự đoán chữ viết tay và hiểu ngữ nghĩa. Mạng RNN có khả năng lưu trữ thông tin từ các bước trước đó trong chuỗi dữ liệu, nhờ đó rất hữu ích cho việc phân tích các chuỗi thời gian. Tuy nhiên, RNN gặp phải vấn đề về biến mất hoặc bùng nổ gradient khi chuỗi dữ liệu quá dài, gây khó khăn trong việc học và dự đoán chính xác.

#### ***2.4.2 Mô hình CNN***

Convolutional Neural Network (CNN) là một mô hình học sâu tiên tiến, giúp xây dựng các hệ thống thông minh với độ chính xác cao. CNN được thiết kế đặc biệt để xử lý dữ liệu có cấu trúc dạng lưới, như hình ảnh hoặc dữ liệu không gian. Mạng sử dụng các lớp tích chập (convolutional layers) để tự động trích xuất đặc trưng từ dữ liệu đầu vào, giảm thiểu sự can thiệp thủ công trong việc thiết kế đặc trưng. Các lớp này có khả năng nhận diện các mẫu phức tạp thông qua việc áp dụng các bộ lọc (filters), giúp học được các đặc trưng như cạnh, hình dạng và kết cấu. CNN đã chứng minh hiệu quả vượt trội trong các ứng dụng nhận dạng hình ảnh và phân loại, nhưng cũng có thể áp dụng cho các bài toán khác như xử lý chuỗi thời gian, cảm biến và video.

Mô hình CNN bao gồm nhiều lớp convolution kết hợp với các hàm kích hoạt phi tuyến như ReLU hoặc tanh để tạo ra các đặc trưng trừu tượng, giúp các lớp tiếp theo học được các thông tin phức tạp hơn. Trong mạng nơ-ron truyền thẳng (Feedforward Neural Network), các lớp được kết nối trực tiếp với nhau qua các trọng số (weight vector). Các lớp này còn được gọi là các lớp kết nối đầy đủ (fully connected layer) hay affine layer. Tuy nhiên, trong CNN, các lớp kết nối với nhau thông qua cơ chế convolution. Mỗi lớp tiếp theo sẽ nhận được kết quả từ phép toán convolution của lớp trước đó, tạo ra các kết nối cục bộ. Điều này có nghĩa là mỗi nơ-ron ở lớp sau được sinh ra từ việc áp dụng một bộ lọc (filter) lên một vùng ảnh cục bộ của lớp trước. Mỗi lớp trong mạng có thể sử dụng hàng trăm đến hàng nghìn bộ lọc khác nhau. Bên cạnh đó, một số lớp khác như lớp pooling hay subsampling được sử dụng để lọc và giữ lại các thông tin quan trọng, đồng thời loại bỏ các nhiễu không cần thiết.

Mạng CNN là lựa chọn lý tưởng cho bài toán phát hiện vận động bất thường nhờ khả năng trích xuất đặc trưng hiệu quả từ dữ liệu không gian và thời gian. Khi áp dụng vào các dữ liệu cảm biến, CNN có thể nhận diện các mẫu chuyển động đặc trưng như ngã, chạy, đi bộ hay các vận động bất thường khác bằng cách sử dụng các lớp tích chập để tự động học các đặc trưng quan trọng mà không cần phải xử lý phức tạp trước. Điều này giúp CNN đặc biệt phù hợp với việc phân tích dữ liệu từ các cảm

biến gia tốc và con quay hồi chuyển, nơi các chuyển động nhỏ hoặc nhanh có thể bị bỏ qua bởi các mô hình khác. Hơn nữa, với khả năng tính toán hiệu quả và yêu cầu tài nguyên thấp, CNN có thể dễ dàng triển khai trên các thiết bị nhỏ gọn như đồng hồ thông minh, thiết bị IoT, giúp theo dõi và phát hiện vận động bất thường trong thời gian thực mà không gây ảnh hưởng đến hiệu suất hệ thống.

## **2.5 Cảm biến và tập dữ liệu sử dụng trong mô hình vận động bất thường**

Thiết bị sử dụng cho việc thu thập dữ liệu bao gồm vi điều khiển ESP32 (hình 2.3a), cảm biến gia tốc MPU6050 (hình 2.3b) với tần số thu thập là 50Hz. Cảm biến MPU6050 là một hệ thống cơ điện vi mô (MEMS) bao gồm một cảm biến gia tốc 3 trục và cảm biến con quay hồi chuyển 3 trục bên trong nó. Cảm biến này giúp đo giá trị gia tốc, vận tốc, hướng, độ dịch chuyển và nhiều thông số liên quan đến chuyển động khác của đối tượng. Vi điều khiển ESP32-S3 là một sản phẩm tiên tiến của Espressif Systems, được thiết kế để đáp ứng các yêu cầu ngày càng cao trong các ứng dụng IoT và thiết bị biên IoT (có thể kết nối Internet và thường bao gồm các cảm biến. Những cảm biến này thu thập dữ liệu và sau đó chuyển nó đến bộ phận xử lý. Ở đây, dữ liệu được xử lý cục bộ thay vì phải trải qua trình chuyển tiếp lên đám mây và phản hồi lại kết quả) thông minh. Với CPU dual-core Xtensa LX7 đạt tần số lên đến 240 MHz, ESP32-S3 cung cấp hiệu suất vượt trội, đặc biệt trong việc xử lý các thuật toán phức tạp. Vi điều khiển này được tối ưu hóa cho các ứng dụng AI/ML với các lệnh vector tích hợp, giúp tăng cường khả năng thực hiện các tác vụ như nhận dạng hình ảnh, giọng nói, và phân tích dữ liệu học máy. Ngoài ra, ESP32-S3 còn hỗ trợ RAM lên đến 512 KB và khả năng kết nối PSRAM ngoài, kèm theo các chuẩn kết nối không dây tiên tiến như Wi-Fi 802.11 b/g/n (2.4 GHz) và Bluetooth 5.0 BLE, đảm bảo tính linh hoạt cao. Bên cạnh đó, ESP32-S3 còn hỗ trợ các giao thức giao tiếp ngoại vi như SPI, I2C, UART, ADC và USB OTG, với số lượng chân GPIO lên đến 45, phù hợp cho các ứng dụng nhúng đòi hỏi đa dạng giao tiếp. Khả năng bảo mật cũng là điểm mạnh với các tính năng mã hóa phần cứng AES, SHA, và RSA, giúp bảo vệ dữ liệu an toàn. Với các chế độ tiết kiệm năng lượng như Deep Sleep, ESP32-S3 đặc biệt phù hợp cho các thiết bị chạy pin, giúp kéo dài thời gian hoạt động. Nhờ

những ưu điểm vượt trội này, ESP32-S3 được ứng dụng rộng rãi trong các hệ thống IoT, thiết bị biên IoT, và đặc biệt là các ứng dụng AI như nhận dạng vận động bất thường, đảm bảo tính chính xác và khả năng triển khai trên các thiết bị nhúng nhỏ gọn, điển hình như khi kết hợp với cảm biến MPU6050.

Tập dữ liệu bao gồm 5 loại vận động, trong đó gồm 4 loại vận động bình thường như đứng yên, ngồi xuống, đứng lên và đi bộ; còn lại là vận động ngã với các tư thế ngã khác nhau. Độ dài tổng thể của tập dữ liệu là 2 giờ đồng hồ.



(a)



(b)

**Hình 2.3. Linh kiện sử dụng thu thập dữ liệu (a) cảm biến MPU6050 (b) vi điều khiển ESP32-S3**

## 2.6 Kết luận chương 2

Trong chương này, đề án đã nghiên cứu các thuật toán và cảm biến được ứng dụng trong việc phát hiện vận động bất thường thông qua mô hình trí tuệ nhân tạo.



Đầu tiên, chương đã giới thiệu tổng quan về các loại cảm biến thường được sử dụng trong việc nhận diện vận động, từ đó hiểu rõ vai trò của chúng trong hệ thống phát hiện bất thường. Đề án cũng đã trình bày sơ đồ tổng quát của một hệ thống phát hiện bất thường, nhấn mạnh quy trình xử lý dữ liệu cảm biến - một bước quan trọng giúp tối ưu hóa độ chính xác của các thuật toán phát hiện. Những thuật toán này, bao gồm phương pháp thống kê, phương pháp dựa trên khoảng cách điểm dữ liệu và các phương pháp học máy, đã được phân tích để đánh giá hiệu quả trong việc phát hiện các hoạt động không bình thường. Cuối cùng, cảm biến và tập dữ liệu thu thập để dùng cho mô hình phát hiện vận động bất thường cũng được trình bày trong chương này. Những kiến thức này sẽ là cơ sở để triển khai hệ thống phát hiện bất thường trong thực tế, đồng thời giúp cải thiện khả năng nhận diện thông qua việc áp dụng trí tuệ nhân tạo.

## **CHƯƠNG 3 - ÁP DỤNG HỌC MÁY VÀO PHÁT HIỆN VẬN ĐỘNG BẤT THƯỜNG**

Học sâu, đặc biệt là các phương pháp dựa trên mạng nơ-ron nhân tạo, đã mở ra khả năng khai thác và xử lý thông tin từ nhiều lớp dữ liệu phi tuyến tính, giúp tự động trích chọn và phân loại các đặc trưng quan trọng. Các lớp này được tổ chức theo cấu trúc thứ bậc, trong đó đầu ra của lớp trước là đầu vào của lớp tiếp theo. Những tiến bộ vượt trội trong kỹ thuật học sâu đã thay thế hiệu quả các phương pháp học thủ công, mang lại những cải tiến đáng kể trong các lĩnh vực như thị giác máy tính, nhận dạng âm thanh và xử lý ngôn ngữ tự nhiên. Trong lĩnh vực nhận dạng hoạt động ở người, học sâu đóng vai trò quan trọng trong việc tự động phát hiện các đặc trưng liên quan đến hành vi, đặc biệt là những hành vi phức tạp và không lặp lại. Các nghiên cứu đã chứng minh rằng mạng CNN, một mô hình học sâu ưu việt, có thể xử lý chuỗi thời gian một chiều từ dữ liệu cảm biến để học các phụ thuộc giữa các mẫu đầu vào, từ đó nhận diện chính xác các hoạt động.

Tuy nhiên, một thách thức lớn hiện nay là việc áp dụng học sâu để phát hiện vận động bất thường (VĐBT), đặc biệt đối với những vận động phức tạp trong thực tế. Các mô hình học sâu thường yêu cầu một lượng dữ liệu lớn để đạt hiệu quả, trong khi đó dữ liệu về vận động bất thường lại tương đối khan hiếm. Bên cạnh đó, quá trình huấn luyện các mô hình học sâu phức tạp nhằm đạt độ chính xác cao thường đòi hỏi các hệ thống máy tính có cấu hình mạnh mẽ, điều này gây khó khăn khi triển khai trên các thiết bị biên IoT hoặc phần cứng hạn chế tài nguyên. Những thách thức này đòi hỏi các giải pháp tối ưu hóa, như áp dụng Tiny ML, để thu nhỏ và tinh chỉnh mô hình học sâu, cho phép chúng hoạt động hiệu quả ngay cả trên các vi điều khiển nhỏ gọn mà vẫn đảm bảo độ chính xác và tính khả thi trong các ứng dụng thực tiễn. Trong chương này, đề án sẽ đề xuất mô hình mạng CNN kết hợp với Tiny ML, nhằm thu nhỏ kích thước và tối ưu hóa mô hình học sâu để triển khai trên các thiết bị phần cứng nhỏ gọn như vi điều khiển ESP32-S3. Cách tiếp cận này không chỉ nâng cao khả năng nhận diện và phân loại các vận động bất thường mà còn đảm bảo hệ thống có thể hoạt

động hiệu quả trên các thiết bị biên IoT với tài nguyên hạn chế, mở rộng tiềm năng ứng dụng thực tế.

### 3.1 Mô hình đề xuất


Hình 3.1 mô tả tổng quan về hệ thống phát hiện vận động bất thường bao gồm các thành phần:

- Khối cảm biến và dữ liệu: Thành phần này chịu trách nhiệm thu thập dữ liệu từ các cảm biến MPU6050, như cảm biến gia tốc và con quay hồi chuyển, để giám sát các chuyển động và hành vi của người dùng. Dữ liệu thu được sẽ được chuyển tiếp tới khối vi điều khiển để xử lý tiếp.
- Khối vi điều khiển ESP32-S3: Đây là trung tâm xử lý của hệ thống, nơi các thuật toán học máy, như mạng nơ-ron nhân tạo (CNN), được triển khai để phân tích và nhận diện các vận động bất thường. Vi điều khiển cũng có nhiệm vụ lưu trữ, xử lý dữ liệu đầu vào từ cảm biến và đưa ra kết quả dựa trên các mô hình học sâu.
- Khối hiển thị và cảnh báo: Sau khi dữ liệu được phân tích và vận động bất thường được phát hiện, khối này sẽ chịu trách nhiệm thông báo kết quả cho người sử dụng, thông qua các cảnh báo hiển thị trên màn hình hoặc phát ra âm thanh, thông báo để can thiệp kịp thời.

**Bảng 3.1. Mô tả chi tiết phần cứng sử dụng**

Tên	Đặc điểm
Cảm biến MPU6050	Con quay hồi chuyển: <ul style="list-style-type: none"> <li>• Cảm biến 3 trục với thang đo: <math>\pm 250</math>, <math>\pm 500</math>, <math>\pm 1000</math>, <math>\pm 2000</math> °/s</li> </ul> Gia tốc kế: <ul style="list-style-type: none"> <li>• Cảm biến 3 trục với thang đo: <math>\pm 2g</math>, <math>\pm 4g</math>, <math>\pm 8g</math>, <math>\pm 16g</math>.</li> </ul> Điện áp hoạt động: 3-5VDC Giao diện kết nối: I2C
Vi điều khiển ESP32-S3	WiFi: IEEE 802.11b/g/n CPU và bộ nhớ: <ul style="list-style-type: none"> <li>• Xtensa dual-core 32 bit LX7</li> <li>• Clock: 240 MHz</li> <li>• ROM: 384 kB</li> </ul>

	<ul style="list-style-type: none"> <li>• SRAM: 512 kB</li> </ul> Ngoại vi: GPIO, I2C, UART, I2S, PWM, SD/MMC, DMA, ADC, Timer. Hỗ trợ véc-tơ lệnh tối ưu cho tính toán mạng nơ-ron và xử lý tín hiệu.
--	----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------



**Hình 3.1. Mô hình hệ thống đề xuất phát hiện vận động bất thường**

Từ đó, hệ thống phát hiện vận động bất thường sử dụng mô hình học sâu được thực hiện theo 3 giai đoạn và 6 bước chính:

- Bước 1: Thu thập dữ liệu
- Bước 2: Tiền xử lý dữ liệu
- Bước 3: Trích chọn đặc trưng
- Bước 4: Huấn luyện mô hình học sâu
- Bước 5: Thực hiện mô hình, triển khai trên thiết bị phần cứng
- Bước 6: Đánh giá mô hình

Trong đó, các bước từ 1 đến 4 được trình bày chi tiết ở mục 3.1, bước 5 được mô tả ở mục 3.2, và bước 6 được đề cập trong mục 3.3. Sự phối hợp chặt chẽ giữa các bước này giúp đảm bảo hệ thống hoạt động hiệu quả từ việc xử lý dữ liệu thô đến ứng dụng thực tiễn trên thiết bị phần cứng.

### **3.1.1 Dữ liệu thu thập**

Phần cứng thu thập dữ liệu được ghép nối và thể hiện trong hình 3.2. Tập dữ liệu được thu thập thông qua vi điều khiển ESP32-S3 kết hợp với cảm biến MPU6050 với tần số đọc là 50Hz. Sau mỗi lần đọc dữ liệu từ cảm biến MPU6050, vi điều khiển ESP32 sẽ đóng gói ba loại dữ liệu tương ứng với giá trị gia tốc trên trục không gian ba chiều *Oxyz* thành một bản tin theo định dạng JSON. Sau đó bản tin JSON được chuyển tiếp tới máy tính để cá nhân để lưu trữ thành dữ liệu dạng bảng theo định dạng

tệp CSV thông qua giao thức MQTT. Trong đề án, đề án tận dụng broker MQTT mã nguồn mở Mosquitto nhằm tối đa hóa khả năng truyền thông giữa vi điều khiển và máy tính cá nhân.



**Hình 3.2. Phần cứng thiết bị phát hiện vận động bất thường**

Bộ dữ liệu thu thập được có dung lượng 1 giờ 30 phút 49 giây, 1600 tệp định dạng CSV, gồm năm trạng thái hoạt động của con người. Cụ thể tập dữ liệu được trình bày trong bảng 3.1 Tập dữ liệu mô tả năm trạng thái cơ bản trong hoạt động của con người bao gồm: đứng yên, đi bộ, ngồi xuống, đứng lên và ngã. Đặc biệt dữ liệu về trạng thái Ngã được thu thập theo nhiều góc và hướng ngã khác nhau nhằm cung cấp một bộ dữ liệu đầy đủ nhất cho quá trình trích xuất đặc trưng và huấn luyện mô hình tiếp theo.

**Bảng 3.2. Chi tiết tập dữ liệu thu thập**


STT	Trạng thái	Thời lượng	Dung lượng (MB)
1	Đứng yên	26 phút 40 giây	4.419
2	Đi bộ	26 phút 37 giây	4.418
3	Ngồi xuống	12 phút 6 giây	2.067
4	Đứng lên	12 phút 5 giây	2.064
5	Ngã	14 phút 20 giây	2.431

Trong quá trình thu thập dữ liệu, đề án tiến hành phân chia dữ liệu cho hai quá trình huấn luyện và kiểm thử với tỉ lệ 80/20 cho mỗi trạng thái dữ liệu thu thập.

### ***3.1.2 Tiền xử lý dữ liệu***

Quá trình loại bỏ tín hiệu nhiễu thường được thực hiện trong bước tiền xử lý dữ liệu và thường không liên quan trực tiếp đến các mô hình học máy. Tuy nhiên, để đạt hiệu quả, thuật toán lọc cần xác định một ngưỡng nhất định để loại bỏ các tín hiệu nhiễu không mong muốn. Trong khuôn khổ của đề tài này, đề án sử dụng cảm biến quán tính đeo trên người do đó dữ liệu lấy được từ các cảm biến có thể bị nhiễu hoặc/và đôi khi bị mất (dropped). Trong trường hợp lý tưởng, nếu cảm biến gia tốc được thiết lập ở tần số lấy mẫu 50 Hz thì mỗi giây sẽ cho ra 50 mẫu với 3 giá trị trên 3 trục  $x$ ,  $y$ ,  $z$ . Trong thực tế, nhiều yếu tố có thể dẫn đến việc mất mát mẫu giá trị, chẳng hạn như sự can thiệp của các vật liệu kim loại giữa cảm biến và máy thu tín hiệu, hoặc các yếu tố tác động bên ngoài khiến chuyển động của con người trở nên bất thường.

Thêm vào đó, chất lượng sản xuất cảm biến cũng có thể sinh ra nhiễu. Trong các trường hợp như vậy, một ngưỡng lọc thường được áp dụng để loại bỏ nhiễu và tái tạo các giá trị thích hợp cho các mẫu bị mất. Các bộ lọc dữ liệu nhiễu thường sử dụng bộ lọc thông thấp để loại bỏ các mẫu có giá trị thấp bất thường và bộ lọc thông cao để loại bỏ các mẫu có giá trị cao bất thường. Những tín hiệu ngoài ngưỡng này sẽ không được cho phép qua bộ lọc. Sau đó, các mẫu được phân chia vào các khung hoặc cửa sổ thời gian. Nếu số lượng mẫu trong một khung nhỏ hơn 75% so với bình thường, khung đó có thể bị loại bỏ do thiếu thông tin để phân lớp các vận động. Ngược lại, khung sẽ được lấy mẫu lại bằng phương pháp nội suy Cubic Spline để bù đắp cho mẫu bị mất. Phương pháp này tương tự như cách các kỹ sư sử dụng thiết bị Spline để vẽ các đường cong đẹp và mượt mà. Họ xác định các điểm (nút) cần thiết và dùng thiết bị Spline để uốn cong qua các điểm đó, từ đó tạo ra đường cong mịn màng, không bị gãy khúc.

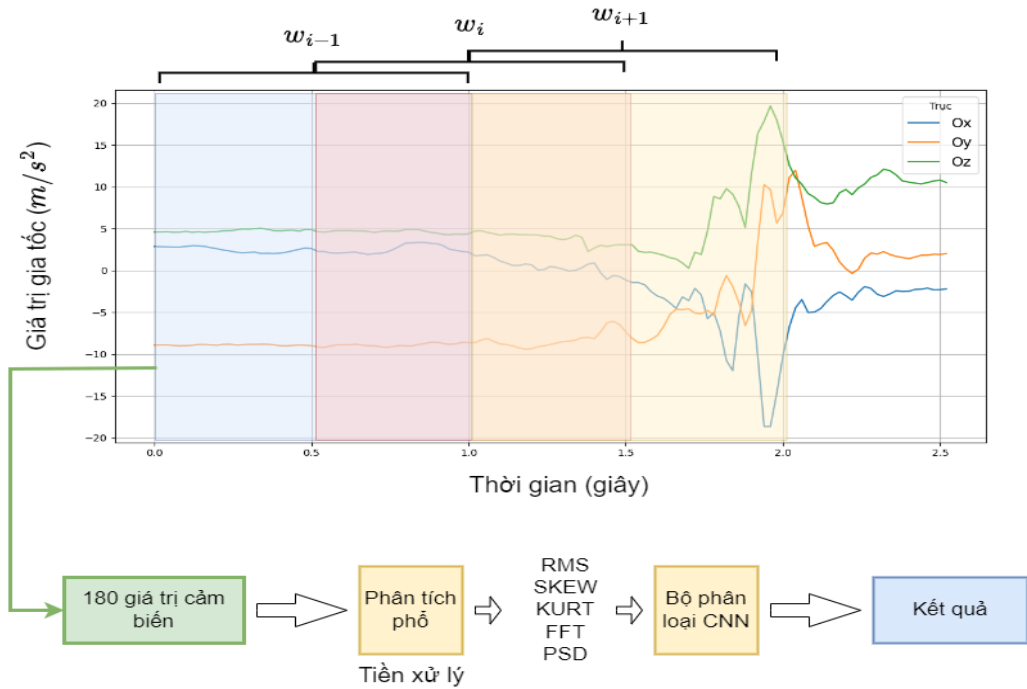


**Hình 3.3. Tiền xử lý dữ liệu thu thập**

Để cải thiện độ chính xác của tín hiệu cảm biến, ngoài việc sử dụng bộ lọc thông thấp/cao, các thử nghiệm còn kết hợp thêm bộ lọc Kalman để giảm nhiễu. Bộ lọc này rất phù hợp với các tín hiệu rời rạc và tuyến tính, vì nó sử dụng chuỗi các giá trị đo lường có thể bị nhiễu hoặc sai số, nhằm ước lượng lại biến số và nâng cao độ chính xác so với việc chỉ dựa vào một giá trị đo lường duy nhất. Ưu điểm nổi bật của bộ lọc Kalman là khả năng ước tính trạng thái không chỉ trong quá khứ và hiện tại mà còn trong tương lai một cách hiệu quả, đồng thời nó vẫn hoạt động tốt ngay cả khi độ chính xác thực tế của mô hình chưa được biết rõ. Bộ lọc này được ứng dụng rộng rãi trong các lĩnh vực như định hướng, định vị, điều khiển phương tiện di chuyển, xử lý tín hiệu, và thậm chí trong các phân tích kinh tế. Hình 3.3 thể hiện tín hiệu gốc thu được từ gia tốc kế (đường màu xanh) và tín hiệu đã được lọc nhiễu (đường màu vàng). Phần trên là tín hiệu sau khi sử dụng bộ lọc thông thấp (Low-pass filter), còn phần dưới là tín hiệu được xử lý bằng bộ lọc Kalman.

### 3.1.3 Trích chọn đặc trưng

Dữ liệu thô từ cảm biến chứa nhiều hoặc dữ liệu sai lệch. Để chuẩn đổi dữ liệu sang dạng bảng, ta áp dụng phương pháp của sổ trượt. Cụ thể, dữ liệu thu được từ hai cảm biến ở tốc độ lấy mẫu 50Hz, kích thước của sổ trượt 2 giây, mỗi cửa sổ sẽ bao gồm 400 điểm dữ liệu ( $3 \text{ trục gia tốc } x,y,z \times 1 \text{ giây} \times 50 \text{ mẫu}$ ). Mỗi bước của sửa này di chuyển 1 giây để tạo một tập dữ liệu lớn hơn. Dữ liệu tiếp theo được xử lý sử dụng kỹ thuật FFT với tham số kích thước 128 mẫu và tần số 400 mẫu trên 1 giây. Quá trình này giúp trích chọn các đặc trưng từ dữ liệu gốc như: phổ công suất, RMS, độ lệch, và độ nhọn trong phân bố dữ liệu, áp dụng cho cả hai miền thời gian và tần số. Kết thúc quá trình tiền xử lý, ta thu được 207 đặc trưng từ bốn loại dữ liệu (x, y, z và A). Các đặc trưng tại miền thời gian bao gồm: RMS ( $\times 1$ ), độ lệch ( $Skew \times 1$ ), độ nhọn ( $Kurtosis \times 1$ ). Các đặc trưng tại miền tần số bao gồm: phổ công suất (PSD  $\times 64$ ), độ lệch ( $Skew \times 1$ ), độ nhọn ( $Kurtosis \times 1$ ). Tóm lại, mỗi loại dữ liệu sẽ bao gồm 69 đặc trưng được trích xuất (3 ở miền thời gian và 66 ở miền tần số), do đó toàn bộ tập dữ liệu sẽ bao gồm  $3 \times 69 = 207$  đặc trưng.




**Hình 3.4. Quá trình tiền xử lý dữ liệu sử dụng FFT kết hợp cửa sổ trượt**



### 3.1.4 Mô hình học sâu

Đây được coi là phần cốt lõi của hệ thống phát hiện bất thường vận động bất thường thông minh. Về mô hình học sâu, đề án sử dụng mô hình CNN kết hợp với mạng nơ-ron kết nối đầy đủ để trích xuất và phân loại dữ liệu thành các trạng thái đã gán nhãn trước đó.



**Hình 3.5. Trực quan hóa mô hình học sâu phát hiện vận động bất thường**

Các thành phần chính trong mô hình CNN được thể hiện ở hình 3.5 bao gồm:

- Lớp tích chập: chứa một tập các bộ lọc có thể “học”, gọi là nhân, là các ma trận kích thước nhỏ, trượt qua toàn bộ dữ liệu đầu vào và tính toán các điểm giữa trọng số của bộ lọc và giá trị dữ liệu tương ứng.
- Lớp kích hoạt: Bằng việc thêm hàm kích hoạt vào vào đầu ra của lớp tích chập, các lớp kích hoạt thêm tính phi tuyến vào mạng CNN.
- Lớp gộp: Lớp này được thêm vào định kỳ vào trong mạng CNN, chức năng chính của lớp gộp là giảm kích thước của kết quả giúp tăng tốc độ tính toán, ngoài ra nó cũng đảm bảo tránh bị overfitting.
- Lớp phẳng: Kết quả của ma trận đặc trưng được chuyển đổi thành dạng một chiều.
- Lớp nơ-ron kết nối đầy đủ: Từ kết quả của các lớp trước để tính toán kết quả phân loại cuối cùng hoặc thực hiện nhiệm vụ hồi quy.

CNN khác với các thuật toán học máy cổ điển ở chỗ nó có khả năng tự động trích xuất được các đặc trưng của dữ liệu với quy mô lớn, ta có thể bỏ qua quá trình

tìm kiếm dữ liệu đặc trưng thủ công. Các lớp tích chập cho phép CNN các đặc tính bất biến dịch, cho phép nó xác định và trích xuất các mẫu cũng như đặc trưng từ dữ liệu bất kể các biến thể về vị trí, hướng, tỷ lệ hoặc dịch thuật. Không chỉ được ứng dụng trong việc phân loại hình ảnh, CNN rất linh hoạt và được ứng dụng trong nhiều lĩnh vực khác như xử lý ngôn ngữ tự nhiên, phân tích dữ liệu theo thời gian và nhận dạng giọng nói. Hơn nữa, để có thể phù hợp khi triển khai trên các thiết bị nhúng, mô hình dựa trên CNN là cần thiết. Mô hình CNN thích hợp cho việc phân loại hình ảnh, âm thanh và dữ liệu từ cảm biến như cảm biến gia tốc. Thêm vào đó, CNN không yêu cầu nhiều trong quá trình tiền xử lý dữ liệu, quá trình trích chọn đặc trưng hoàn toàn tự động mà không cần sự tinh chỉnh thủ công so với các loại mô hình truyền thống khác. Ngoài ra, trong mô hình học sâu đề xuất, đề án có sử dụng thêm mạng nơ-ron kết nối đầy đủ, điều này giúp mô hình có thể học mối tương quan giữa các đặc trưng được trích ra bởi mạng CNN. Về cài đặt các tham số trong mô hình học sâu của đề tài, điều này thường không có một quy chuẩn chung. Đối với các thiết bị nhúng nhỏ gọn và hạn chế tài nguyên, cần tối thiểu hóa các tham số sao cho vẫn duy trì được độ chính xác cao. Những giá trị tham số cũng như hàm được sử dụng trong mô hình là những ví dụ điển hình cho một mô hình học sâu sử dụng mạng CNN. Thông qua những lần thử nghiệm thực tế, đề tài chọn được một bộ tham số cho kết quả đầu ra với một độ chính xác tương đối cao. Chi tiết thông số cài đặt cho từng lớp trong mô hình học sâu phát hiện vận động bất thường được trình bày trong bảng 3.3.

**Bảng 3.3. Chi tiết mô hình học sâu phát hiện vận động bất thường**

<b>Lớp</b>	<b>Tham số</b>	<b>Định nghĩa</b>
Đầu vào	207	Số lượng các đặc trưng đầu vào
Reshape	23 cột	Chuyển mảng đặc trưng đầu vào thành dạng dữ liệu đa chiều.
1D-Conv	32	Số lượng bộ lọc sử dụng trong lớp tích chập
	3	Kích thước bộ (nhân) sử dụng trong lớp tích chập
	1	Số lượng lớp tích chập
Gộp giá trị lớn nhất (Max)	2-2	Chọn giá trị lớn nhất trong 2 giá trị với bước nhảy là 2.
Lớp phẳng		Chuyển dữ liệu đa chiều sang đơn chiều

		(Sau khi dữ liệu đi qua mạng tích chập cần “làm phẳng” để trở về trạng thái ban đầu).
Lớp nơ-ron kết nối đầy đủ	32	Mạng nơ-ron kết nối đầy đủ gồm 32 nút.
Loại bỏ (dropout)	0.1	Ngẫu nhiên loại bỏ một nốt của mạng nơ-ron nhằm giảm nguy cơ mô hình bị overfitting.
Lớp nơ-ron kết nối đầy đủ	16	Mạng nơ-ron kết nối đầy đủ gồm 16 nút.
Đầu ra	5	Phân loại kết quả trạng thái từ dữ liệu đầu vào: gồm 5 trạng thái.

Ngoài ra, trong các lớp ẩn như lớp tích chập hay các lớp mạng nơ-ron liên kết đầy đủ, đề án sử dụng hàm kích hoạt là ReLU. Bởi hàm kích hoạt ReLU đơn giản, không có ngưỡng bão hòa, không tuyến tính, và cực kỳ hiệu quả khi xảy ra hiện tượng “vanishing gradient”, điều này khiến mô hình học nhanh hơn và cải thiện hiệu suất của mô hình. Hàm kích hoạt ReLU có thể được mô tả theo toán học trong công thức (3.1) với đầu vào là giá trị đầu vào của nơ-ron. Sự đơn giản này là điều khiến ReLU trở nên hiệu quả trong việc đào tạo mạng lưới thần kinh sâu, vì nó giúp duy trì tính phi tuyến tính mà không cần các phép biến đổi phức tạp, cho phép các mô hình học hiệu quả hơn. Tại lớp nơ-ron đầu ra của mô hình, đề án sử dụng hàm kích hoạt “softmax”.

$$f(x) = \max(0, x) = \begin{cases} x, & \text{nếu } x > 0 \\ 0, & \text{nếu } x \leq 0 \end{cases} \quad (3.1)$$


### 3.2 Thực hiện mô hình

Trong quá trình xây dựng và triển khai mô hình, việc huấn luyện và thực thi mô hình học máy trên vi điều khiển được thực hiện trên nền tảng Edge Impulse. Đây là một nền tảng đám mây mạnh mẽ, được thiết kế để hỗ trợ phát triển các ứng dụng trí tuệ nhân tạo trên các hệ thống nhúng và thiết bị biên IoT với tài nguyên hạn chế. Edge Impulse nổi bật nhờ các nguyên tắc cốt lõi như khả năng truy cập dễ dàng, tối

ưu hóa hiệu suất trung tâm dữ liệu, và hỗ trợ cộng tác chéo trong các tầng công nghệ. Với sự ứng dụng rộng rãi trong công nghiệp, nghiên cứu và giáo dục, Edge Impulse không chỉ giúp đơn giản hóa quy trình triển khai AI mà còn tạo điều kiện học hỏi từ các dự án thực tiễn, mở ra cơ hội giải quyết những vấn đề lớn hơn trong tương lai.

Trong quá trình huấn luyện mô hình, tập dữ liệu chia ngẫu nhiên tập dữ liệu thành hai phần: 80% cho quá trình huấn luyện và 20% cho quá trình kiểm thử và đánh giá. Như trong hình 3.4, đầu vào của mô hình sẽ bao gồm 207 giá trị đặc trưng từ tập dữ liệu đã qua xử lý. Sau đó, chuyển đổi chúng thành cấu trúc dữ liệu phù hợp với yêu cầu đầu vào của lớp tích chập. Cuối cùng kết quả đầu ra của mô hình là tập 5 trạng thái tương ứng với tên nhãn đã liệt kê trong bảng 3.2.

Sau quá trình huấn luyện và xác thực mô hình, đề án triển khai chúng trên một thiết bị nhúng, cụ thể ở đây là vi điều khiển ESP32-S3. Để triển khai được mô hình xuống vi điều khiển ESP32-S3, nền tảng Edge Impulse sẽ lượng tử hoá (quantization) mô hình theo hai lựa chọn khác nhau, trong đó có float32 và int8. Float32 là một loại dữ liệu kiểu số thực (floating-point) với 32 bit. Trong quá trình lượng tử hóa float32, nền tảng sẽ chọn một số lượng tử hóa nhất định, ví dụ như chia khoảng giá trị từ giá trị tối thiểu đến giá trị tối đa thành một số lượng hạng mục cố định và sử dụng giá trị gần nhất trong nhóm đó để biểu diễn. Int8 là một loại dữ liệu số nguyên có dấu với 8 bit. Trong quá trình lượng tử hóa int8, nền tảng giới hạn phạm vi giá trị từ -128 đến 127 (với 1 bit để biểu diễn dấu) và làm tròn các giá trị nằm ngoài phạm vi này về giá trị gần nhất trong phạm vi. Việc lựa chọn giá trị theo int8 sẽ làm tăng tốc độ nhận diện vận động, giảm tiêu tốn tài nguyên phần cứng, nhưng lại làm giảm độ chính xác của mô hình, trong khi vi điều khiển ESP32 có phần cứng đáp ứng được mô hình được lượng tử hoá theo kiểu float32. Vì vậy, chúng ta quyết định chọn kiểu lượng tử hoá float32. Nền tảng Edge Impulse giúp chuyển đổi mô hình học máy dưới dạng thư viện C++ kèm theo Edge Impulse SDK, giúp dễ dàng triển khai mô hình học máy vào trong ESP32-S3 hoặc bất cứ loại vi điều khiển hay máy tính nhúng nào khác. Điều này cho phép mô hình có thể hoạt động mà không cần tới kết nối Internet, từ đó giảm độ trễ và hoạt động với mức tiêu thụ năng lượng tối thiểu.



**Hình 3.6. Hình ảnh triển khai thiết bị vận động bất thường trên thực tế**

Ngoài ra, khi xây dựng mô hình để triển khai, đề án có thêm vào các lớp tối ưu sử dụng trình biên dịch EON. Trình biên dịch EON cho phép sử dụng mạng nơ-ron nhân tạo với ít bộ nhớ RAM hơn, tiết kiệm bộ nhớ Flash hơn, trong khi vẫn duy trì được độ chính xác của mô hình ban đầu. Thêm vào đó, đề án có sử dụng thêm lượng tử hóa mô hình từ định dạng dữ liệu là số thực 32 bit (float32) về dạng số nguyên 8 bit (int8). Điều này giúp mô hình dễ dàng tích hợp vào vi điều khiển hơn vì vi điều khiển.

Hình 3.6 minh họa thiết bị phát hiện vận động bất thường đã được triển khai thành công, cho thấy khả năng hoạt động hiệu quả trong môi trường thực tế. Thiết bị được thiết kế nhỏ gọn, tích hợp cảm biến và vi điều khiển để xử lý dữ liệu tại chỗ.

### **3.3 Kiểm thử và đánh giá**

#### **3.3.1 Các tham số đánh giá**

Phát hiện bất thường là quá trình xác định dữ liệu sai trong các tập dữ liệu lớn, nhằm cải thiện chất lượng xử lý dữ liệu tiếp theo. Phương pháp phát hiện bất thường sẽ phân loại dữ liệu thành các giá trị bình thường và bất thường. Việc lựa chọn phương pháp phát hiện tốt nhất phụ thuộc rất nhiều vào đặc điểm của tập dữ liệu. Do đó, cần các tham số để đánh giá hiệu suất của các phương pháp khác nhau trên một tập dữ liệu nhất định.

**Bảng 3.4. Ma trận nhầm lẫn (confusion matrix)**

	Dự đoán
--	---------

		Bình thường	Bất thường
Thực tế	Bình thường	TP	FN
	Bất thường	FP	TN

Thông thường, để đánh giá chất lượng của quá trình phân loại, ma trận nhầm lẫn (confusion matrix), hoặc một số liệu dẫn xuất từ nó được sử dụng. Các loại tham số này cho kết quả tin cậy đối với tập dữ liệu không có đơn vị liên quan đến thời gian. Bảng ma trận nhầm lẫn (confusion matrix) tóm tắt hiệu suất của các thuật toán phân loại. Ma trận nhầm lẫn (confusion matrix) cơ bản bao gồm bốn loại số liệu chính được sử dụng để định nghĩa các thông số đánh giá của bộ phân loại:

- Khẳng định đúng (TP – True Positive): TP đại diện cho các kết quả của mô hình khi cho dữ liệu đầu vào, và kết quả đầu ra đúng với nhãn mà nó được gán. Ví dụ đối với bài toán phát hiện bất thường thì kết quả của một dữ liệu bình thường khi qua mô hình sẽ trả lại kết quả là bình thường.
- Phủ định đúng (TN – True Negative): TN đại diện cho các kết quả của mô hình dự đoán dữ liệu phủ định là phủ định. Trong ví dụ phát hiện bất thường, TN là số các dữ liệu bất thường được dự đoán là bất thường.
- Khẳng định sai (FP – False Positive): FP đại diện cho các kết quả mà các dữ liệu sai nhưng mô hình dự đoán là đúng. Trong bài toán phát hiện bất thường, FP là số các dữ liệu thực tế là bất thường nhưng kết quả trả về là bình thường.
- Phủ định sai (FN – False Negative): FN đại diện cho các kết quả mà các dữ liệu đúng nhưng mô hình dự đoán là sai. Trong bài toán phát hiện bất thường, FN là số các dữ liệu thực tế là bình thường nhưng mô hình trả về kết quả là bất thường.

Ngoài ma trận nhầm lẫn (confusion matrix) dùng để đánh giá hiệu năng của mô hình, các tham số được tính toán từ ma trận nhầm lẫn (confusion matrix) cũng đóng một vai trò quan trọng trong quá trình đánh giá.

- Accuracy: Tỷ lệ dự đoán chính xác tổng quát của mô hình (cả bất thường và bình thường).

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.2)$$

- Precision: Tỷ lệ dự đoán chính xác trường hợp bình thường của dữ liệu.

$$Precision = \frac{TP}{TP + FP} \quad (3.3)$$

- Recall: Hay còn gọi là độ nhạy – là tỷ lệ dự đoán chính xác các dữ liệu mà kết quả của mô hình dự đoán là bình thường trong tổng số các dữ liệu so với tổng số các dữ liệu bình thường trong toàn bộ tập dữ liệu.

$$Recall = \frac{TP}{TP + FN} \quad (3.4)$$

- F1-Score: Là giá trị được tổng hợp từ Precision và Recall.


$$F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \quad (3.5)$$

### 3.3.2 Đánh giá hiệu năng mô hình


Để đánh giá hiệu năng của mô hình đề xuất, trước tiên, các tham số quan trọng như độ chính xác (accuracy), độ nhạy (recall), độ chính xác dự đoán (precision), và F1-score được sử dụng. Những tham số này giúp đánh giá mức độ chính xác của mô hình trong việc phân loại các trạng thái vận động khác nhau, bao gồm cả những vận động bất thường như ngã. Kết quả đánh giá các tham số này sẽ giúp xác định hiệu quả tổng thể của mô hình, đồng thời so sánh với các phương pháp khác để chứng minh tính ưu việt của hệ thống đề xuất.

Hình 3.7 và 3.8 mô tả độ chính xác của quá trình huấn luyện và quá trình xác thực mô hình với từng giá trị epoch. Bắt đầu từ epoch 1 tới 10, độ chính xác của quá trình huấn luyện và xác thực mô hình thay đổi nhanh từ 0% lên tới 98%. Từ epoch 6 trở đi, độ chính xác tiếp tục có sự tăng nhẹ và bão hòa tại 99%. Hình 3.5 mô tả độ mất mát tương ứng trong quá trình huấn luyện và xác thực mô hình. Từ epoch thứ 25 trở đi, mô hình đạt độ chính xác xấp xỉ 99.6% và độ chính xác khi xác thực là 98.6%, điều này chỉ ra rằng mô hình không bị thiên hướng lệch về một kết quả nào đó, hay

còn gọi là overfitting. Trong khi đó, độ mất mát của mô hình tương ứng lần lượt là 0.02 và 0.05, mô hình có khả năng thích ứng tốt, có thể áp dụng cho những dữ liệu mới chưa biết.




**Hình 3.7. Độ chính xác theo giá trị Epoch trong quá trình huấn luyện và xác thực**



**Hình 3.8. Giá trị mất mát theo giá trị Epoch trong quá trình huấn luyện và xác thực**


Để đánh giá hiệu suất của mô hình hay thuật toán học máy một cách chi tiết hơn, đề án có sử dụng bảng ma trận nhầm lẫn (confusion matrix). Ma trận nhầm lẫn là ma trận vuông dạng  $N \times N$ , trong đó  $N$  là số lượng nhãn có trong dữ liệu đầu vào. Ma trận nhầm lẫn (confusion matrix) được mô tả chi tiết trong Hình 3.9 của kiểm thử mô hình. Ngoài ra, một số thông số để đánh giá mô hình học máy được dẫn xuất từ ma trận nhầm lẫn (confusion matrix) như *accuracy*, *precision*, *recall*, và giá trị *F1-score*.





**Hình 3.9. Ma trận nhầm lẫn của mô hình trong quá trình kiểm thử**

Hình 3.10 và bảng 3.5 trình bày các tham số đánh giá như *precision*, *recall*, và *F1-score* đối với từng trạng thái vận động bao gồm: ngã, đứng yên, ngồi xuống, đứng lên, và đi bộ. Kết quả cho thấy các tham số đều đạt giá trị trên 95% cao nhất là 99.8%, phản ánh rõ ràng khả năng dự đoán tốt, tính chính xác cao, và hiệu quả của mô hình được triển khai. Điều này khẳng định rằng mô hình học sâu được đề xuất có thể phân biệt chính xác các trạng thái vận động, ngay cả trong các trường hợp phức tạp hoặc dữ liệu khó phân biệt, góp phần nâng cao độ tin cậy và tính ứng dụng thực tiễn của hệ thống.



**Hình 3.10. Các tham số đánh giá cho từng trạng thái hoạt động**

**Bảng 3.5. Tham số đánh giá cho từng loại dữ liệu**

Nhãn	Precision	Recall	F1-Score
Ngã	0.985	0.949	0.967
Đứng yên	0.998	0.996	0.997
Ngồi xuống	0.940	0.963	0.952
Đứng lên	0.977	0.998	0.995
Đi bộ	0.992	0.998	0.995

Thêm vào đó, để kiểm thử độ chính xác của thiết bị trong thực tế, đề án đã tiến hành các thử nghiệm thực tiễn bằng cách mô phỏng tình huống ngã. Hình 3.11 minh họa tình huống khi người bị ngã, hệ thống ngay lập tức phát ra âm thanh cảnh báo thông qua còi. Điều này khẳng định thiết bị phát hiện vận động bất thường đã được triển khai thành công và hoạt động hiệu quả trong môi trường thực tế. Với thiết kế nhỏ gọn, thiết bị tích hợp cảm biến và vi điều khiển để xử lý dữ liệu trực tiếp, đảm bảo khả năng phản ứng nhanh chóng và chính xác. Hệ thống không chỉ đáp ứng các yêu cầu về độ chính xác trong phát hiện vận động bất thường mà còn sở hữu tính linh hoạt, phù hợp để ứng dụng trong nhiều tình huống, đặc biệt là giám sát người cao tuổi hoặc hỗ trợ trong các ứng dụng y tế. Thành công này là minh chứng rõ nét cho việc tích hợp các mô hình học sâu vào thiết bị nhỏ gọn thông qua công nghệ Tiny ML, mở

ra triển vọng phát triển các giải pháp thông minh trên các hệ thống nhúng và thiết bị biên với tài nguyên hạn chế.



**Hình 3.11. Tình huống người ngã và còi cảnh báo sẽ kêu**

### **3.4 Kết luận chương 3**

Chương 3 của đề án tập trung vào quá trình xây dựng, huấn luyện và triển khai mô hình học sâu nhỏ TinyML trên nền tảng Edge Impulse. Đầu tiên, chương bắt đầu bằng việc trình bày về việc xây dựng thiết bị phần cứng cần thiết cho việc thu thập dữ liệu, trong đó thiết bị phần cứng sử dụng cảm biến MPU6050 để lấy dữ liệu các giá trị. Tiếp theo, chương 3 tập trung vào quá trình xây dựng tập dữ liệu huấn luyện. Điều này bao gồm việc phát triển chương trình để đọc dữ liệu từ cảm biến MPU6050 và thu thập dữ liệu vận động cần thiết cho quá trình huấn luyện. Sau khi có được tập dữ liệu, chương 3 diễn giải về quá trình huấn luyện mô hình. Điều này bao gồm việc tải dữ liệu lên đề án, gắn nhãn dữ liệu, xây dựng quy trình huấn luyện mô hình. Bên cạnh đó, chương cũng giải thích về việc trích chọn đặc trưng của vận động thông qua cài đặt thông số và quy trình trích chọn đặc trưng. Cuối cùng, chương 3 nói về quá trình tiến hành kiểm thử mô hình, lựa chọn phương pháp lượng tử hoá mô hình và xây dựng thư viện từ mô hình đã huấn luyện để có thể triển khai vào vi điều khiển ESP32.

## KẾT LUẬN VÀ KIẾN NGHỊ

Sau quá trình làm đề án “*Nghiên cứu ứng dụng học máy để phát hiện vận động bất thường*”, quyền đề án đã trình bày bám sát nội dung của đề cương đã được duyệt bao gồm 3 chương:

- ✓ Chương 1: Tổng quan bài toán phát hiện bất thường
- ✓ Chương 2: Nghiên cứu thuật toán và cảm biến phát hiện vận động bất thường ứng dụng mô hình học máy
- ✓ Chương 3: Áp dụng học máy vào phát hiện vận động bất thường

Đề án tập trung vào việc phát triển hệ thống phát hiện vận động bất thường (VĐBT) sử dụng học sâu, với mục tiêu nâng cao khả năng nhận diện các hành vi bất thường như ngã, đứng yên, ngồi xuống, đứng lên và đi bộ. Hệ thống được xây dựng dựa trên mô hình CNN và triển khai thành công trên các thiết bị phần cứng nhỏ gọn như vi điều khiển ESP32-S3 thông qua nền tảng TinyML. Quá trình thực hiện bao gồm sáu bước chính: thu thập dữ liệu từ cảm biến quán tính (MPU6050), tiền xử lý dữ liệu, trích chọn đặc trưng, huấn luyện mô hình, triển khai mô hình trên phần cứng, và đánh giá hiệu năng. Thiết bị tích hợp cảm biến và vi điều khiển giúp xử lý dữ liệu ngay tại chỗ, đảm bảo khả năng hoạt động trong thời gian thực với độ chính xác cao. Kết quả thử nghiệm cho thấy hệ thống đạt các tham số hiệu năng vượt trội (precision, recall, F1-score > 95%) và hoạt động hiệu quả trong thực tế. Sản phẩm không chỉ đảm bảo tính chính xác trong phát hiện vận động mà còn mang lại sự linh hoạt, phù hợp với các ứng dụng như giám sát người cao tuổi, chăm sóc y tế và các tình huống cần cảnh báo khẩn cấp. Đề án khẳng định tiềm năng của việc tích hợp học sâu vào thiết bị nhỏ gọn, mở ra hướng phát triển mới cho các hệ thống nhúng và biên thông minh.

## DANH MỤC TÀI LIỆU THAM KHẢO

- [1] Nguyễn Tuấn Linh (2021); Phát hiện vận động bất thường(ngã) sử dụng cảm biến đeo, Luận án tiến sỹ, Học viện Công nghệ Bưu chính viễn thông
- [2] Newaz, N.T.; Hanada, E.The Methods of Fall Detection: A Literature Review. *Sensors* **2023**, 23, 5212. <https://doi.org/10.3390/s23115212>
- [3] Liu, H.; Xue, T.; Schultz, T. On a Real Real-Time Wearable Human Activity Recognition System. In Proceedings of the 16th International Joint Conference on Biomedical Engineering Systems and Technologies-WHC. INSTICC, SciTePress, Lisbon, Portugal, 16–18 February 2023; pp. 711–720.
- [4] Noury, N.; Fleury, A.; Rumeau, P.; Bourke, A.K.; Laighin, G.; Rialle, V.; Lundy, J.E. Fall detection-principles and methods. In Proceedings of the 2007 29th Annual International Conference of the IEEE Engineering in Medicine and Biology Society, Lyon, France, 22–26 August 2007; pp. 1663–1666.
- [5] Mubashir, M.; Shao, L.; Seed, L. A survey on fall detection: Principles and approaches. *Neurocomputing* **2013**, 100, 144–152.
- [6] Igual, R.; Medrano, C.; Plaza, I. Challenges, issues and trends in fall detection systems. *Biomed. Eng. Online* **2013**, 12, 66.
- [7] Withings. [Online]. Available: <http://www.withings.com/uk/> (accessed on 15/10/16).
- [8] Almaslukh, B., AlMuhtadi, J., Artoli, A. (2017), An effective deep autoencoder approach for online smartphone-based human activity recognition, *International Journal of Computer Science and Network Security* 17, 160.
- [9] Róisín McNaney, Ivan Poliakov, John Vines, Madeline Balaam, Pengfei Zhang, and Patrick Olivier (2015), LApp: A Speech Loudness Application for People with Parkinson’s on Google Glass, In proc. Of the ACM international conference on Human Factors in Computing Systems (CHI) 2015, pp.497- 500.
- [10] F. Bianchi, S.J. Redmond, M.R. Narayanan, S. Cerutti, N.H. Lovell (2010), Barometric pressure and triaxial accelerometry-based falls event detection, *IEEE Trans. Neural Syst. Rehabil. Eng.* 18 (6) 619-627.

## **BẢN CAM ĐOAN**

Tôi cam đoan đã thực hiện việc kiểm tra mức độ tương đồng nội dung luận văn qua phần mềm “**Kiểm Tra Tài Liệu**” một cách trung thực và đạt kết quả mức độ tương đồng không quá **13%** toàn bộ nội dung luận văn. Luận văn này sau khi đã kiểm tra qua phần mềm và bản cứng luận văn đã nộp để bảo vệ trước hội đồng. Nếu sai tôi xin chịu các hình thức kỷ luật theo quy định hiện hành của Học viện.

Hà Nội, ngày 22 tháng 12 năm 2024

**Tác giả luận văn**

**Cao Việt Anh**




## BÁO CÁO KIỂM TRA TRÙNG LẬP

### Thông tin tài liệu

Tên tài liệu:	MasterThesis_Activity_Tracking
Tác giả:	Cao Việt Anh
Điểm trùng lặp:	13
Thời gian tải lên:	00:11 22/12/2024
Thời gian sinh báo cáo:	00:14 22/12/2024
Các trang kiểm tra:	53/53 trang



### Kết quả kiểm tra trùng lặp



HỌC VIÊN  
(Ký và ghi rõ họ tên)

NGƯỜI HƯỚNG DẪN KHOA HỌC  
(Ký và ghi rõ họ tên)